

台灣自編大學教科書

地圖建構與同步定位 (SLAM)

Simultaneous Localization and Mapping



大學
教科書

第五篇

第 17 ~ 19 章

3D 光達 SLAM 與自主巡檢

李世淵 (機器人叫獸)

台灣自編大學教科書

[@prof](#)

《地圖建構與同步定位》

Simultaneous Localization and Mapping, SLAM

第五篇 3D 光達 SLAM 與自主巡檢

第 17 章

3D 點雲與光達建圖

編者：李世淵（機器人叫獸）

助教：李天宇、李宇晴

大學智慧機器人學程 / 高中 AI 機器人社團課程

本章在全書的位置


第五篇從這一章開始，而這一章要做的事，是把前四篇累積的一切從平面抬進立體。這個轉換聽起來只是多了一個 z 座標，實際上改變的東西比想像中多：地圖不再是一張可以印出來的圖片，而是數千萬個三維點；配準不再是三個自由度，而是六個；資料量從幾 MB 跳到幾 GB。本章的四項工具——降採樣、ICP、NDT、地圖表示——就是為了應付這個量級跳躍而存在的。

值得注意的是，本章幾乎沒有全新的數學。ICP 是第 13.3 節的三維版，NDT 的核心是第 11 章的多維高斯分布，配準的最佳化是第 12 章的最小平方，座標變換是第 10 章的剛體運動。真正新的只有「規模」——以及規模帶來的工程問題。這也是為什麼本章花了整整一節談降採樣：在三維世界裡，「如何把資料變少而不失真」本身就是一門學問。

圖 17-0 第 17 章的連結地圖

前四篇的既有工具

第 8 章 3D 光達 第 10 章 剛體變換 第 11 章 高斯分布



【第 17 章 3D 點雲：規模帶來的問題】

降採樣 — ICP / NDT 配準 — 地圖表示 — 顏色化



第 18 章 LOAM 第 20 章 3D SLAM 系統 第 21 章 巡檢應用

學習目標

第四篇的 2D SLAM 讓機器人在平面上定位建圖，但真實世界是立體的：樓梯有高度、天花

板有管線、機器狗要跨越障礙、無人機要在三維空間穿梭。本章把維度從平面提升到立體，介紹三維點雲的處理與配準技術，為第五篇的 3D SLAM 與自主巡檢揭開序幕。學完本章之後，同學應能夠達成下列目標：

1. 說明 3D 點雲的資料結構、來源與特性，並理解它與 2D 佔據格地圖的根本差異。
2. 說明體素降採樣的原理與必要性，並能估算降採樣的效果。
3. 說明 ICP 點雲配準的流程、變體與限制。
4. 說明 NDT 的核心思想，並比較它與 ICP 的差異與適用場合。
5. 說明 3D 地圖的表示方式與室內空間掃描的流程。
6. 說明點雲顏色化的原理與彩色三維視覺建模的應用。
7. 舉例說明 3D 空間建模在工廠、校園與展場的實際應用價值。

核心概念

中文名詞	英文名詞	概念說明
點雲	Point Cloud	由大量三維點組成的空間資料，每點含 x、y、z 座標。
體素	Voxel	三維空間中的立方格，相當於 2D 的像素在立體中的對應。
體素降採樣	Voxel Grid Downsampling	把空間切成體素，每格只保留一個代表點以減量。
點雲配準	Point Cloud Registration	求兩片點雲之間的旋轉與平移，使其對齊。
迭代最近點	ICP	反覆找對應點並求最佳變換的經典配準演算法。
點對面 ICP	Point-to-Plane ICP	ICP 變體，以點到平面的距離為誤差，收斂較快。

中文名詞	英文名詞	概念說明
常態分布轉換	NDT	把點雲轉為體素內的高斯分布再匹配的配準方法。
法向量	Normal Vector	描述點所在表面朝向的向量，用於點對面配準與著色。
KD 樹	KD-Tree	加速最近鄰搜尋的空間資料結構，ICP 的效率關鍵。
八叉樹	Octree	以遞迴細分表示三維空間的樹狀結構，用於壓縮地圖。
點雲顏色化	Colorization	把相機影像的顏色投影到點雲上，產生彩色模型。
數位分身	Digital Twin	真實空間或設備的高精度三維數位模型。

17.1 3D 點雲資料

第 8 章介紹過點雲是 3D 光達的輸出格式，本節深入它的結構與特性，這是整個第五篇的資料基礎。

點雲是什麼

點雲 (Point Cloud) 是由大量三維點構成的集合。最基本的形式中，每個點只有三個數字—— x 、 y 、 z 座標，代表「空間中的這個位置有一個表面」。把數十萬個這樣的點畫出來，物體與環境的立體形狀就浮現了。

每個點還可以附帶額外欄位：

- 反射強度 (Intensity)：雷射回波的強弱，反映表面材質與顏色深淺。金屬與反光標誌强度高、黑色物體低。
- 顏色 (RGB)：若融合了相機影像，每點可帶顏色，形成彩色點雲 (17.6 節)。
- 線號 (Ring)：多線光達中，該點來自第幾條雷射線。這個資訊在第 18 章的 LOAM 特徵提取中非常重要。
- 時間戳記：該點被量測的精確時刻，用於運動補償 (第 18 章)。

點雲的三大特性

- 無序性：點雲是一堆點的集合，沒有固定的排列順序。這與影像的規則像素格不同——影像可以直接套用卷積，點雲不行。這也是深度學習處理點雲時的一大挑戰。
- 稀疏且不均勻：近處的點密集、遠處的點稀疏 (第 8 章的角解析度公式)；而且只有「表面」有點，物體內部與沒掃到的地方都是空的。
- 資料量龐大：一台 64 線光達每秒可產生上百萬個點。一趟十分鐘的掃描就是數億個點——這是 17.2 節必須降採樣的原因。

與 2D 佔據格地圖的根本差異

特性	2D 佔據格地圖 (第 13 章)	3D 點雲
資料結構	規則格網，每格一個機率值	無序的點集合
空間表示	佔據 / 自由 / 未知三態	只有「表面在這裡」
未知區域	明確標示 (灰色)	無法區分「沒東西」與「沒掃到」
記憶體	與面積成正比	與點數成正比，通常大得多
直接用於規劃	可以	不方便，需轉換
細節保真度	受解析度限制	極高，保留原始量測

表 17-1 2D 佔據格地圖與 3D 點雲的比較

請特別注意「未知區域」這一系列。第 13 章強調過佔據格地圖能區分「確定空」與「未知」，這對路徑規劃至關重要；但純點雲沒有這個能力——沒有點的地方，可能是真的空，也可能只是雷射沒掃到。這正是實務上常把點雲轉換成 3D 佔據格（如八叉樹）的原因（17.5 節）。

17.2 Voxel Grid 降採樣

面對動輒數千萬點的資料，第一件要做的事幾乎總是降採樣（Downsampling）——減少點數，同時盡量保留形狀。體素降採樣是最常用、也最直觀的方法。

原理：一格只留一個代表

體素（Voxel）是三維版的像素——把空間切成邊長固定的小立方格。體素降採樣的做法極其簡單：

1. 把整個點雲所在的空間，切成邊長為 d 的體素格網。
2. 把每個點分配到它所在的體素。
3. 每個體素只輸出一個代表點——通常取該體素內所有點的重心（平均座標）。
4. 空的體素直接忽略。

結果是：原本密集區域的大量點被合併成少數幾點，稀疏區域則幾乎不受影響。點雲整體變得均勻而輕量，形狀卻大致保留。


取重心還是取中心

這裡有一個看似細微、實則重要的實作差異。取體素內所有點的重心（質心），能較忠實地反映真實表面位置；若圖快而直接取體素中心，速度較快但精度較差。研究比較顯示，精確的體素降採樣結果幾乎與標準實作一致，而近似版本可能產生虛假的點，最多可能多出兩倍的點數。對精度要求高的建圖，建議使用取重心的精確版本。

降採樣的效果與代價

- 效果：體素邊長 d 越大，保留的點越少。點數的減少大致與 d 的立方成反比——邊長加倍，點數約降為八分之一。這是三維空間的必然結果。
- 代價：細節流失。若體素邊長大於物體特徵尺寸（例如 20 公分的體素配上 5 公分的管線），該特徵就會消失。
- 取捨： d 應略小於「你關心的最小特徵尺寸」。室內建圖常用 5 至 10 公分，大範圍戶外可用 20 至 50 公分。

圖 17-1 體素降採樣：看得見的取捨與一條可以驗算的定律



這張圖來自一次真實的模擬掃描：一間 $10 \times 7 \times 2.8$ 公尺的室內空間，由 64 線光達從七個位置掃描並合併，共 1,075,200 個點。圖(a)到(c)是俯視圖（為了看清楚結構，顯示時濾掉了地板與天花板），顏色代表高度。可以看到牆面、中央隔牆與門口、以及書櫃、工作檯、機櫃等家具的輪廓。

比較三張圖就能理解降採樣的取捨。體素邊長 0.05 公尺時 (圖 b)，點數從一百零七萬降到八萬六，減量超過九成，但牆線、家具輪廓與門口位置全部保留——這就是 17.2 節所說「點雲整體變得均勻而輕量，形狀卻大致保留」。到了 0.20 公尺 (圖 c)，點數只剩五千兩百，牆開始變成一串斷續的點，家具退化成幾個色塊，門口的位置已經難以辨認。本章天花板上那三根直徑 18 公分的管線，在這個尺度下也接近消失。

圖(d) 把這件事變成一條可以驗算的定律。橫軸是體素邊長、縱軸是輸出點數，兩軸都取對數。實測點落在一條直線上，斜率 -1.93 ——非常接近公式一所預測的 -2 ，而明顯偏離實心體積的 -3 (圖中點線)。這印證了 17.2 節那個容易被忽略的重點：光達掃到的是物體「表面」而非內部，所以點雲本質上是一個嵌在三維空間裡的二維曲面，點數隨邊長的平方而非立方遞減。實務上的速算法就是：體素邊長加倍，點數大約降為四分之一。

唯一偏離直線的是最左邊 0.01 公尺那一點。原因不難理解：當體素比原始點的平均間距還小時，大多數體素裡只有一個點，降採樣幾乎沒有作用，點數被原始取樣密度卡住。這給了一個實用的判斷準則——如果你把體素調小卻發現點數不再明顯增加，代表已經觸及感測器本身的解析度下限，再小只是浪費計算。

體素邊長怎麼選

準則： d 應略小於「你關心的最小特徵尺寸」。要看到 5 公分的管線，體素就不能用 10 公分。

室內建圖常用 0.05 ~ 0.10 公尺；大範圍戶外或車載可用 0.20 ~ 0.50 公尺。

配準用的點雲可以比展示用的更稀疏——本章圖 17-3 的配準實驗就是在 0.06 公尺下進行的。

檢查方法：把體素逐步調小，記錄點數。當點數不再隨之上升，就是感測器解析度的極限。

KISS-ICP 等近年系統有一個值得注意的細節：體素內保留「一個原始點」而非重

心，以避免重心計算引入的離散化誤差（見 17.8 節）。

其他降採樣策略

除了體素法，還有幾種常見策略，各有適用場合：

- 隨機降採樣：隨機丟棄一定比例的點。最快，但可能造成分布不均。
- 均勻降採樣：每隔固定間隔取一點，簡單但不考慮密度。
- 距離門檻法：確保輸出點之間至少相距某個距離。
- 最遠點取樣：反覆挑選離已選點最遠的點，分布最均勻但計算較慢，常用於深度學習前處理。
- 保邊降採樣：近年的改良方向，依點雲特徵動態調整降採樣密度，並特意保留邊緣資訊，避免關鍵特徵流失。

本書實作以體素降採樣為主——它在效果、速度與實作難度之間取得最好的平衡，也是 PCL 與 Open3D 等主流函式庫的預設選擇。

17.3 ICP 點雲配準

點雲配準 (Registration) 是 3D SLAM 的核心運算：給定兩片部分重疊的點雲，求出把其中一片對齊到另一片所需的旋轉與平移。這正是第 13.3 節掃描匹配的三維版本，而 ICP 依然是最經典的方法。

ICP 的三步驟循環

迭代最近點 (Iterative Closest Point, ICP) 的流程與第 13 章介紹的 2D 版本完全相同，只是在三維空間中進行：

1. 找對應：對來源點雲中的每個點，在目標點雲中找最近的點，配成一對。

2. 求變換：計算一個旋轉 R 與平移 t (第 10 章的剛體變換)，使所有配對點之間的距離平方和最小。
3. 更新並迭代：把變換套用到來源點雲，回到步驟 1 重新找對應，反覆進行直到變換量小於門檻 (收斂)。

效率關鍵：KD 樹

步驟 1 的「找最近點」是 ICP 最耗時的部分。若用暴力法，每個點都要與目標點雲的所有點比較，對數十萬點的點雲完全不可行。

解法是使用 KD 樹 (KD-Tree) ——一種把空間遞迴切分的資料結構，能把最近鄰搜尋從線性時間降到對數時間。實務上，建立 KD 樹與搜尋的效率，往往決定了整個 ICP 的速度。這也是為什麼現代配準函式庫會特別強調平行化的 KD 樹實作。

ICP 的重要變體

- 點對點 ICP(Point-to-Point)：最原始的形式，誤差是兩點之間的直線距離。實作簡單，但在平面滑動時收斂慢。
- 點對面 ICP(Point-to-Plane)：誤差改為「來源點到目標點所在平面的垂直距離」。這個改動讓點能沿著平面自由滑動而不受懲罰，大幅加快收斂——這正是實務上最常用的版本。代價是需要先估計每個點的法向量。
- 廣義 ICP(GICP)：同時考慮來源與目標的局部平面結構，穩健度更高。
- 體素化加速版本：先降採樣再配準，或以體素結構加速對應搜尋，在保持精度的同時提升速度。

ICP 的三個限制

- 需要好的初始猜測：ICP 是局部最佳化，若兩片點雲的初始位置差太遠，會收斂到錯誤的局部最佳解。這是第 13.3 節就強調過的老問題——實務上靠里程計或 IMU 提供初始值。

- 怕結構退化：在長廊、隧道、平坦大面等缺乏幾何約束的場景，點雲可以沿某個方向自由滑動而誤差不變，ICP 無法確定該方向的位移。這是第 13.6 節走廊困境的三維版本。
- 對離群點敏感：動態物體（走動的人）、雜訊點會拉扯配準結果。實務上需搭配離群點剔除或穩健核函數（第 12、15 章）。

17.4 NDT Normal Distributions Transform

ICP 有一個根本的效率瓶頸：每次迭代都要找最近點對應。常態分布轉換（NDT）提出了一個完全不同的思路——不找對應點，而是把點雲轉換成連續的機率分布。

核心思想：把點雲變成機率場

NDT 的做法是：

1. 把目標點雲所在空間切成體素（格子）。
2. 對每個體素，計算內部所有點的均值與共變異數——也就是用一個三維高斯分布來描述「這一格的點大致長什麼樣」（第 11 章的高斯分布）。
3. 於是整片點雲變成一個由許多高斯分布拼成的連續機率場：空間中任一位置，都能算出「這裡有表面的機率密度」。
4. 配準時，求一個變換使來源點雲的所有點，落在這個機率場中的總機率最大。

這個轉換帶來一個關鍵優勢：目標函數變成平滑可微的連續函數，可以直接用牛頓法等最佳化方法求解（第 12 章），而且完全不需要在迭代中反覆搜尋最近點。

圖 17-2 NDT 的核心：把離散的點變成連續的機率場



「把點雲轉換成機率場」這句話聽起來抽象，但畫出來其實非常直觀。為了看得清楚，這張圖取前一張那間室內空間在高度 1.0 公尺處的一片水平切片，把問題降到二維來示範；三維的做法完全相同，只是高斯分布從橢圓變成橢球。

圖(a) 是切片後的點雲，疊上邊長 1.0 公尺的體素格網。此時資料仍然是離散的點，要問「空間中某一個位置有沒有表面」只能去搜尋附近有沒有點——這正是 ICP 每次迭代都要做、也最耗時的事。圖(b) 則對每一格內的點計算均值與共變異數，用一個二維高斯分布來描述它。請注意橢圓的形狀本身就帶著資訊：落在牆上的格子，橢圓被拉成細長的條狀，長軸方向正是牆面的走向；落在轉角的格子，橢圓則比較接近圓形。換句話說，共變異數矩陣自動記錄了「這一格的表面朝哪個方向延伸」。

圖(c) 把這 82 個高斯分布拼起來，就成了一個連續的機率場。現在，空間中任意一點都能直接代入公式算出「這裡有表面的機率密度」，不需要搜尋、不需要 KD 樹。更關鍵的是，這個函數是平滑可微的，可以直接丟給第 12 章的牛頓法去求極值。ICP 的「找對應—求變換」兩步循環，在 NDT 裡被壓縮成單純的一個最佳化問題。

不過這張圖也誠實暴露了 NDT 的一個弱點：仔細看圖(c) 會發現機率場在體素邊界處是斷掉的，同一面牆跨越兩格時，亮帶會出現接縫。這是因為每一格各算各的高斯，格與格之間並不連續。實際的 NDT 實作會用重疊體素或插值來緩和這個問題，而這也正是下一節要談的「體素解析度」之所以是 NDT 最敏感參數的原因。

讀懂橢圓：共變異數的幾何意義

橢圓的長軸方向 = 該格點分布變異最大的方向，也就是表面延伸的方向。

橢圓越扁 = 這一格的點越集中在一個平面上，法向量方向的約束越強。

接近圓形 = 點分布沒有明顯方向性（轉角、雜亂區域或點數太少）。

本書實作對共變異數設了 0.05 公尺的下限：真實表面有量測雜訊，不該被描述成零厚度。少了這道正規化，高斯會退化成一條線，最佳化會變得極不穩定。

每格至少要有五個點才建立高斯——點太少時共變異數估計不可靠，寧可留白。

NDT 與 ICP 的比較

比較項目	ICP	NDT
核心運算	找最近點對應	體素內的高斯分布
是否需搜尋對應	需要（KD 樹加速）	不需要
大量點雲速度	較慢	較快
精度	通常較高	略低於 ICP
對初始值敏感度	較敏感	較不敏感，收斂範圍較大
關鍵參數	對應距離門檻	體素解析度
適合場景	精細配準、點數較少	大範圍、大量點雲、初值較差

表 17-2 ICP 與 NDT 的比較

研究比較指出，NDT 在配準過程中不使用對應點的特徵來計算，對於大量點雲資料，配準速度比 ICP 快，但配準精度不如 ICP。這個結論相當一致地出現在多項實驗中。

圖 17-3 ICP 與 NDT 的正面對決，以及長廊裡的結構退化




表 17-2 用文字比較了兩種方法，這張圖把它變成實測。實驗設定是真實的 SLAM 情境：光達在同一個室內空間的兩個位置各掃描一次（相距約 3.9 公尺、轉過 34 度），兩片點雲只有部分重疊，再以 0.06 公尺體素降採樣，各約兩萬三千點。任務是把第二片對齊回第一片，而且刻意給它一個不準的初始猜測。

圖(a) 是收斂後的精度。三種方法的位移誤差都落在 6.5 到 7.2 公分之間，差距不大——這個數值其實是兩個視點看到的表面取樣不同所造成的下限，而非演算法的極限。真正拉開差距的是角誤差（柱內數字）：點對點 ICP 1.43 度、點對面 ICP 0.83 度、NDT 0.08 度。點對面明顯優於點對點，印證了 17.3 節「點能沿平面自由滑動而不受懲罰」的論述；而 NDT 因為共變異數本身就編碼了表面方向，在角度上表現最好。

圖(b) 是對初始猜測的容忍度，也是本圖最實用的一格。橫軸是初始角偏差，縱軸是最終位移誤差（對數刻度）。三種方法在 15 度以內都穩定收斂到公分級；NDT 在 20 度開始失敗，兩種 ICP 則撐到 20 度、在 30 度崩潰。曲線的形狀值得注意：它不是緩慢劣化，而是斷崖式失敗——一旦超過吸引域，結果就不是「比較差」而是「完全錯」，誤差直接跳到公尺級。這解釋了為什麼實務上必須靠里程計或 IMU 提供初始猜測（17.3 節的第一個限制）：它們不需要很準，只要把誤差壓在十幾度以內就夠了。

圖(c) 則單獨檢驗 17.3 節的第二個限制：結構退化。場景換成一條 90 公尺長、寬度 3.2 公尺的無特徵長廊，長度遠超過光達 25 公尺的量程，所以機器人永遠看不到兩端。紅線是沿

著長廊軸向移動：殘餘誤差等於真實位移本身——位移 1.0 公尺，誤差就是 1.0 公尺，也就是配準完全沒有還原任何位移。綠線是橫向移動，誤差只有一兩公分，完全正常。藍線則是在同一條長廊沿途加上門洞與柱子之後再測軸向：誤差立刻降到公分級。

這三條線把「結構退化」講得再清楚不過：問題不在演算法，而在幾何資訊本身。無特徵長廊沿軸向平移後，點雲看起來一模一樣，配準演算法沒有任何依據可以判斷它移動了多少——再好的最佳化器也變出不存在的資訊。對策只有兩條：靠別的感測器（輪速、IMU、UWB）補上那個方向的約束，或是確保環境裡有足夠的幾何特徵。這也回答了案例 17-2 的隧道難題。

關於這組對照實驗的誠實說明

速度沒有列入比較。本書的 NDT 是以 Python 撰寫的教學實作，而 ICP 用的是 Open3D 的 C++ 實作，兩者相差一個數量級的工程最佳化，比較執行時間並不公平。文獻中 NDT 較快的結論（17.4 節）來自同等最佳化程度的實作。

容忍度的結果與「NDT 對初值較不敏感」的常見說法不同。本實驗中 ICP 使用由粗到細的對應距離排程（1.5 → 0.75 → 0.3 公尺），這對 ICP 相當有利；NDT 的吸引域則取決於體素大小，本書已試過 2 公尺到 8 公尺的多種排程，以 2 公尺起始最佳。

結論該怎麼讀：三種方法在合理初值下都能用，點對面 ICP 與 NDT 的角度精度優於點對點；而「初值必須夠好」「退化場景無解」這兩個限制，對三者一視同仁。

同學可在實作 17-1 第二、三部分重現這三張圖，數字不同是正常的，重要的是趨勢。

NDT 的關鍵參數：體素解析度

NDT 最重要的參數是體素（cell）的邊長。太小則每格點數不足，高斯分布估計不可靠；太大則空間描述過於粗糙，精度下降。有研究針對隧道環境的點雲實測發現，當體素解析度

設為 0.5 公尺時能滿足解析度需求，且配準時間最短。這提醒同學：最佳參數與場景尺度密切相關，室內、隧道、戶外各不相同，必須實測調校。

NDT 與 ICP 的合作

既然 NDT 快而穩健、ICP 精確，自然的想法就是兩者結合：先用 NDT 做粗配準快速拉近，再用 ICP 做精配準提升精度。這種「NDT 粗配準 + ICP 精配準」的組合，在實務系統中相當常見，也再次體現本書反覆強調的思想：沒有萬能的演算法，只有恰當的組合。

17.5 3D 地圖與室內空間掃描

有了降採樣與配準工具，就能把一連串的光達掃描拼接成完整的三維地圖。本節說明 3D 地圖的表示方式與室內掃描的實務流程。

三種 3D 地圖表示

- 原始點雲地圖：直接保存所有（降採樣後的）點。保真度最高、視覺效果最好，但資料量大、無法區分「空」與「未知」、也不方便直接規劃路徑。適合測繪與展示。
- 3D 佔據格（八叉樹）：把空間切成體素並記錄佔據機率，以八叉樹（Octree）遞迴細分——只在有東西的地方細分，空曠處用大格子表示，大幅節省記憶體。這種表示能區分佔據、自由、未知三態，適合機器人導航與避障。第 3 章提過的 OctoMap 即為代表。
- 網格模型（Mesh）：把點雲轉成三角面片構成的表面模型。檔案小、可貼材質、適合建築與遊戲應用，但重建過程較複雜且可能失真。

室內空間掃描流程

1. 規劃掃描路線：確保覆蓋所有想掃描的空間，並在關鍵處（轉角、房間之間）保留足夠的重疊，重疊不足會導致配準失敗。
2. 資料採集：以背包式、手持式或機器人載具緩慢移動掃描（第 15.6 節）。速度要慢，並避免劇烈晃動造成運動變形。

3. 前處理：去除離群點、依需求裁切範圍、體素降採樣 (17.2 節)。
4. 配準拼接：以 NDT 或 ICP 把相鄰掃描對齊 (17.3、17.4 節)，配合 SLAM 的位姿估計。
5. 全域最佳化：偵測閉環並執行圖優化 (第 12、15 章)，消除累積漂移，確保整體一致。
6. 後處理與輸出：視需求轉為八叉樹、網格或加上顏色 (17.6 節)，輸出為標準格式 (如 PLY、PCD、LAS)。

品質評估

與第 13.7 節的 2D 地圖評估相呼應，3D 地圖也需檢查：牆面是否「厚」了 (表示配準有誤差，同一面牆被畫成兩層)、直線結構是否筆直、閉環處是否對齊、以及量測關鍵尺寸與實測值比較。「牆變厚」是 3D 建圖最典型的品質指標——理想的牆面應該是薄薄一層點。

17.6 點雲顏色化與彩色視覺建模

純幾何的點雲雖然精確，但看起來像灰白色的骨架，不易辨識也不好看。加上顏色，點雲才真正成為「數位分身」。

顏色從哪來：投影原理

顏色來自相機影像。原理是第 9 章的針孔投影模型反過來用：

1. 已知相機的內參 K (第 9 章) 與相機相對光達的外參 (第 10 章的座標變換)。
2. 對每個三維點，先用外參把它從光達座標轉到相機座標。
3. 再用內參把它投影到影像平面，得到對應的像素座標。
4. 讀取該像素的 RGB 值，賦予這個三維點。

這個流程再次印證第 10 章的核心價值：精確的座標轉換與外參校正，是多感測器融合的基礎。外參若差幾度或幾公分，顏色就會「貼歪」——牆的顏色跑到窗戶上。

實務挑戰

- 時間同步：光達與相機必須對齊時間戳記。移動中若差幾十毫秒，顏色就會錯位（第 5、10 章的時間同步問題）。
- 遮蔽處理：相機看不到的點（被前方物體擋住）不應被賦予前方物體的顏色。需要做可見性判斷。
- 曝光與色差：不同時刻拍攝的影像亮度不同，拼接後點雲會出現色塊。需做色彩均衡。
- 視野不匹配：光達常為 360 度，相機視野有限。需多台相機或接受部分點沒有顏色。

彩色點雲的價值

- 可讀性：彩色模型讓非技術人員也能一眼看懂——這對向客戶或校方展示專案成果極為重要。
- 語意線索：顏色提供材質與物體的線索，是後續 AI 語意分割的重要輸入（第 32 章）。
- 文化資產保存：古蹟與文物的數位典藏，顏色與紋理是不可或缺的資訊。
- 缺陷檢測：牆面裂縫、鏽蝕、水漬等問題，在幾何上不明顯但在顏色上一目了然。

17.7 工廠、校園、展場的 3D 空間建模

本節說明 3D 建圖的實際應用價值，特別聚焦於大學場域可以實作的方向。

工廠：設施管理與數位分身

工廠的三維模型能用於產線布局規劃（新設備放得下嗎？搬運路徑會不會撞到？）、管線與消防設施記錄、以及設備維護的空間查詢。相關應用會結合預先載入的樓層平面圖輪廓，規劃能抵達每個可進入房間、走廊與機械空間的覆蓋路徑，並在建築物營運時間內確保機器人在人員與設備周圍安全避障。

光達相對相機的關鍵優勢在此格外明顯：不像以相機為基礎的方法在低光或無紋理區域（例如機房與停車場結構）表現不佳，光達不論照明條件如何都能可靠運作，因此成為設施維護應用的明確選擇。

校園：大學場域的實作方向

- 建築測繪：掃描系館內部，產生可用於教學、空間管理與無障礙規劃的三維模型。
- 室內導航地圖：為第九篇的語意導航建立空間基礎，讓機器人知道「電梯在哪、樓梯在哪」。
- 實驗室數位分身：掃描智慧機器人教室，作為模擬環境的基礎——這讓同學能在虛擬的教室中測試演算法，再搬到實體驗證。
- 教學素材：掃描成果本身就是絕佳的教材，讓後續學生看到「我們學校長這樣」的三維模型。

展場與文化資產

展場的三維模型能用於布展規劃、虛擬看展與動線分析；而古蹟與歷史建築的數位保存，更是 3D 掃描最有社會價值的應用之一——一旦建築因天災或歲月損毀，精確的三維紀錄就成為修復的唯一依據。台灣有豐富的歷史建築資源，這是一個兼具技術與人文意義的專題方向。

技術基礎：邊緣運算

值得注意的是，現代 3D 建圖越來越倚賴邊緣運算平台。SLAM 演算法在 NVIDIA Jetson 等邊緣處理器上運行，把個別掃描幀拼接起來，並透過閉環——機器人辨識出先前造訪過的區域，並用這個辨識修正軌跡估計中累積誤差的技術——來修正位置漂移。近年更出現 GPU 加速的體素重建函式庫，能即時建立符號距離場與佔據格，讓機器人在導航的同時重建設施幾何，同時支援建圖與避障。

這意味著 3D SLAM 已經不再是「必須用工作站」的技術，一台掌上型的 Jetson 就能勝

任——這對教學與專題實作是極大的好消息，也是第七篇（邊緣 AI SLAM）與第 32 章要深入的方向。

17.8 點雲處理的當代走向：2024–2026 年的四個動態

ICP 的原始論文發表於 1992 年，NDT 是 2003 年——以本章介紹的技術來說，它們都已經是三十年與二十年級的老方法。有趣的是，它們不但沒有被取代，近年反而出現了一股「回歸基本」的風潮。本節整理四個值得注意的動態。

一、回歸簡單：KISS-ICP 的「為點對點 ICP 辯護」

2023 年波昂大學團隊發表的 KISS-ICP，論文副標題直接寫著「為點對點 ICP 辯護」。他們的主張相當挑釁：與其不斷往光達里程計上疊加複雜度——特徵提取、深度學習模組、閉環偵測、位姿圖最佳化——不如把最基本的點對點 ICP 的幾個環節做對，效果就能與最先進的方法並駕齊驅。

他們做對的環節有四個：以等速度模型預測運動並補償掃描畸變（不需要 IMU 或輪速計）、以體素降採樣建立局部地圖、用穩健核函數做最佳化，以及最關鍵的「自適應對應距離門檻」——門檻不是手動設定，而是由「里程計實際偏離運動預測多少」的統計量自動算出（取三倍標準差）。結果是一套幾乎不需要調參的系統，同一組設定能跨越車載、無人機、手持等不同平台。

對修課同學而言，這個案例的啟示比技術細節更重要：當你的配準效果不好時，第一反應不該是換一個更複雜的演算法，而是檢查降採樣、初始猜測與對應距離門檻這幾個基本環節。本章圖 17-3(b) 的斷崖式曲線已經說明，初值與門檻的影響遠大於演算法的選擇。

二、工程效率：從演算法比較到實作比較

第二個動態是「同一個演算法，不同實作可以差好幾倍」這件事被正式端上檯面。2024 年由日本產業技術綜合研究所 Kenji Koide 發表的 `small_gicp` 函式庫是代表作：它把降採樣、

KD 樹建構與配準全部重寫並平行化，報告指出其體素降採樣比 PCL 快約 1.3 倍（單執行緒）到 3.2 倍（六執行緒），KD 樹建構比 nanoflann 最多快 6 倍，而廣義 ICP 單執行緒就比 PCL 的版本快約 2.4 倍。

這呼應了案例 17-3 的工具選擇討論，也補上一個本章之前沒說的維度：當你在專題報告裡寫「我們用 ICP 做配準」時，這句話其實沒有交代清楚效能——用哪一套實作、有沒有開多執行緒、KD 樹怎麼建，對實際跑起來的速度影響可能比點對點與點對面之別還大。

三、地圖表示的新選項：三維高斯潑濺

第三個動態衝擊的是 17.5 節那張「三種 3D 地圖表示」的清單。近兩年，三維高斯潑濺（3D Gaussian Splatting）快速成為第四種選項：它用大量帶有位置、形狀、顏色與透明度的三維高斯來表示場景，既能像點雲一樣由資料直接擬合，又能像網格一樣算繪出逼真的影像。

這條線已經延伸到光達領域。2025 年的 Splat-LOAM 把高斯潑濺直接當成光達里程計與建圖的表示，而 LiV-GS 一類的工作則把光達與相機整合進同一套高斯潑濺 SLAM，用於戶外場景。同學應該會注意到一個有趣的巧合：NDT 用體素內的高斯描述表面（本章圖 17-2），高斯潑濺用空間中的高斯描述場景外觀——兩者相隔二十年，卻都選擇了「用一堆高斯分布來描述世界」這個答案。

四、學習式配準與傳統方法的分工

最後一個動態是深度學習在配準問題上的定位逐漸清晰。學習式方法的強項在於「找對應」這一步——學出來的三維描述子能在重疊很少、初始猜測極差的情況下，直接找出兩片點雲的對應關係，這正是 ICP 與 NDT 最弱的地方（圖 17-3(b) 的斷崖）。但在對應找到之後，求解變換仍然是第 12 章的最小平方問題，傳統方法又快又準。

因此目前的實務分工相當明確：全域配準（不知道初值，例如重定位與閉環）傾向用學習式描述子或隨機抽樣一致法（RANSAC）；局部精修（已有不錯初值，例如連續幀之間）仍然

是 ICP 與 NDT 的天下。而 KISS-ICP 的存在則提醒我們：在連續掃描的光達里程計這個特定任務上，初值其實一直都夠好，所以傳統方法至今沒有被取代的理由。

四個動態的共同線索

方法面 (KISS-ICP)：複雜度不等於效果，基本環節做對比換演算法更有用。

工程面 (small_gicp)：同一個演算法的不同實作可以差好幾倍，效能是實作問題而非只是理論問題。

表示面 (高斯潑潑)：地圖表示從「點、體素、網格」擴張到「一堆高斯」，與 NDT 的思想遙相呼應。

學習面 (描述子)：深度學習補的是「找對應」，不是「求變換」；兩者是分工而非取代。

共同線索：本章的四樣工具沒有一樣被淘汰，被改變的是它們的使用方式與工程品質。把基礎打穩，才讀得懂後面所有的變化。

承先啟後

本章備齊了三維點雲的處理工具：降採樣讓資料量回到可處理的範圍，ICP 與 NDT 讓相鄰掃描能對齊，地圖表示與顏色化讓成果能被使用與展示。圖 17-1 到圖 17-3 的三組實驗分別驗證了這三件事的定律、原理與極限——特別是圖 17-3(c) 那條紅線，它提醒我們有些誤差不是演算法的錯，而是幾何資訊本身不存在。

但把相鄰掃描逐幀配準再累加，誤差仍會隨距離累積——這正是第 7 章漂移問題的三維版本。下一章的 LOAM 系列給出了一個優雅的答案：與其對整片點雲做配準，不如先從掃描中提取「邊緣點」與「平面點」兩類特徵，只拿特徵去配準。這個想法讓即時的三維光達里程計成為可能，也開啟了第五篇真正的主角。

公式或流程

一、體素降採樣的點數估算

把邊長為 d 的體素套用到點雲上，輸出點數約等於「被佔據的體素數」。由於三維空間的關係：

$$\text{輸出點數} \propto 1 / d^2 \quad (\text{表面型點雲})$$

注意這裡是平方而非立方——因為光達掃到的是「表面」而非實心體積，點主要分布在二維曲面上。實務經驗：體素邊長加倍，點數約降為四分之一。若點雲填滿三維體積（如醫學影像），才會是立方關係。

二、ICP 的目標函數

點對點 ICP 求旋轉 R 與平移 t ，使配對點的距離平方和最小：

$$(R^*, t^*) = \operatorname{argmin} \sum_i \| (R \cdot p_i + t) - q_i \|^2$$

其中 p_i 是來源點雲的點、 q_i 是它在目標點雲中的最近點。點對面 ICP 則把誤差改為沿目標點法向量 n_i 的投影：

$$(R^*, t^*) = \operatorname{argmin} \sum_i ((R \cdot p_i + t) - q_i) \cdot n_i^2$$

差別在於：點對點懲罰「所有方向的偏離」，點對面只懲罰「垂直於表面的偏離」，讓點能沿平面滑動——這正是它收斂較快的原因。

三、NDT 的機率目標

NDT 把目標點雲的每個體素以高斯分布 (μ, Σ) 描述。來源點 p 經變換 T 後落在某體素中，其得分為：

$$\text{score}(p) \propto \exp(-((T \cdot p - \mu)^T \Sigma^{-1} (T \cdot p - \mu)) / 2)$$

配準目標是最大化所有點的總得分：

$$T^* = \operatorname{argmax} \sum_i \text{score}(T \cdot p_i)$$

式中的 $(x - \mu)^T \Sigma^{-1} (x - \mu)$ 正是第 11 章多維高斯分布的核心項（馬氏距離）。同

學可以看出：第三篇的機率數學，在此直接成為 3D 配準的工具。

四、3D 建圖完整流程

圖 17-4 從光達掃描到 3D 地圖的完整流程

① 3D 光達輸出原始點雲（每秒數十萬至上百萬點）



② 前處理：離群點剔除、範圍裁切、運動補償



③ 體素降採樣：減少點數並使分布均勻（17.2 節）



④ 特徵/法向量估計：為點對面 ICP 或後續處理準備



⑤ 配準：NDT 粗配準 → ICP 精配準（17.3、17.4 節）

配合里程計/IMU 提供初始猜測



⑥ 累積拼接：把新掃描併入全域地圖



⑦ 閉環偵測 + 圖優化：消除累積漂移（第 12、15 章）



⑧ 後處理：轉八叉樹/網格、顏色化（17.6 節）、輸出

案例

案例 17-1 牆為什麼會變厚：3D 建圖的品質指標

第一次做 3D 建圖的同學，常會遇到一個令人困惑的現象：掃描完一個房間，從上方俯視點雲，原本應該是薄薄一層的牆面，卻變成厚達十幾公分的「牆板」；甚至有時會看到兩層平行的牆面，中間空著。

這個現象的成因很直接：配準有誤差。機器人在不同時刻從不同位置掃到同一面牆，若位姿估計準確，這些掃描應該完美重疊成一層；若位姿有偏差，同一面牆就被畫在略微不同的位置，疊起來就「變厚」了。偏差大到一定程度，就會出現明顯的雙層牆（這是三維版的「重影」，對應第 13.7 節的 2D 病徵）。

因此「牆的厚度」成為 3D 建圖最實用的品質指標：量測一段牆面點雲在垂直牆面方向的分布厚度，理想值應接近光達本身的量測精度（數公分）。厚度明顯超出，就表示配準或 SLAM 有問題。這個檢查方法簡單、直觀、不需真值，強烈建議同學在每次建圖後都做一次——它能立刻告訴你「這張圖能不能用」。

案例 17-2 從隧道到礦坑：退化場景的三維挑戰

第 13.6 節談過長走廊讓 2D 掃描匹配失效，這個問題在三維世界只會更嚴重。隧道、地下坑道、長廊等場景有一個共同特徵：沿著長軸方向，環境的幾何形狀幾乎不變。點雲可以沿著這個方向自由滑動而不增加配準誤差——這稱為結構退化（Degeneracy）。

針對這類場景，研究者發展出多種對策。有研究團隊在隧道環境中採用「先體素降採樣保持整體結構並減少點數，再以 NDT 求解座標變換並依環境特徵最佳化體素解析度，最後在 ICP 中引入 KD 樹加速點對搜尋並以高斯—牛頓法求解」的組合流程，實測顯示體素解析度設為 0.5 公尺時效果最佳。

這個案例給同學三個啟示：其一，退化場景是 3D SLAM 的共同難題，不是你做錯了；其二，NDT 與 ICP 各有所長，組合使用往往優於單獨使用；其三，參數必須依場景調校，沒有放諸四海皆準的設定。這也預告了第 18 章 LOAM 系列如何用「特徵提取」的方式來對

付這個問題。

案例 17-3 工具的選擇：PCL 與 Open3D

做 3D 點雲處理，幾乎一定會用到兩個開源函式庫：PCL (Point Cloud Library) 與 Open3D。前者是 C++ 為主的老牌工具，功能極為完整，是 ROS 生態的標準配備；後者由 Intel 開發，以 Python 介面友善、視覺化方便著稱，近年在研究與教學中相當流行。

Open3D 提供多種先進表面配準方法的實作，包括成對的全域配準、成對的局部精修，以及使用位姿圖最佳化的多路配準——同學應該立刻認出最後一項正是第 12 章的圖優化，只是用在點雲拼接上。

效能方面，兩者各有勝場。有基準測試比較了不同函式庫的配準速度，結果顯示點對面 ICP 通常比點對點 ICP 快、而 NDT 的速度表現也相當有競爭力；近年更出現專為平行化設計的輕量配準函式庫，把降採樣、KD 樹建構、法向量估計等前處理步驟全面平行化，多執行緒版本可比單執行緒快數倍。

對本書讀者的建議：教學與快速原型用 Open3D (Python 上手快、視覺化好)，整合進 ROS 系統則用 PCL，追求效能的專題可考慮新一代的平行化函式庫。這與第 8 章「先模擬、再便宜硬體、後追求精度」的學習路徑一脈相承。

實作活動

實作 17-1 點雲處理與配準實作

目的：親手完成點雲的載入、降採樣、視覺化與配準，理解 ICP 與 NDT 的行為差異與參數影響。本實作以 Python 搭配 Open3D 為主，不需 3D 光達硬體即可完成。

第一部分：點雲基礎與降採樣 (全體)

1. 安裝 Open3D，載入內建的範例點雲 (或從公開資料集下載一片室內掃描)，用互動視窗旋轉觀察，感受三維點雲的樣貌。

2. 印出點雲的基本資訊：點數、座標範圍（邊界框）、是否含顏色與法向量。
3. 體素降採樣實驗：分別用邊長 0.01、0.05、0.2 公尺降採樣，記錄每次的輸出點數，並驗證是否符合公式一的平方關係。
4. 視覺比較：把原始點雲與三種降採樣結果並排顯示，觀察在什麼體素大小下，牆角、桌腳等細節開始消失。
5. 估計法向量並以顏色顯示（法向量方向對應顏色），觀察牆面、地面、天花板如何被清楚區分——這是點對面 ICP 的前置作業。

第二部分：ICP 配準（全體）

1. 取一片點雲，複製一份並套用一個已知的旋轉與平移（例如繞 Z 軸轉 20 度、平移 0.3 公尺），作為「來源點雲」。
2. 用點對點 ICP 配準，比較估出的變換矩陣與真值，計算誤差，並記錄迭代次數與耗時。
3. 改用點對面 ICP（需先估法向量），比較收斂速度與精度的差異，驗證 17.3 節的論述。
4. 初始值實驗：把初始偏移逐步加大（5 度、20 度、60 度、120 度），找出 ICP 開始失敗的臨界點，親身驗證「ICP 需要好的初始猜測」。

第三部分：NDT 與組合配準（大學部）

1. 用 NDT 做同一組配準，比較它與 ICP 在速度、精度與初始值容忍度上的差異，填入你自己的表 17-2。
2. 體素解析度實驗：調整 NDT 的體素大小（0.2、0.5、1.0 公尺），觀察對成功率與精度的影響，對照案例 17-2 的討論。
3. 實作「NDT 粗配準 + ICP 精配準」的組合流程，比較它與單獨使用任一方法的結果。

4. 退化場景測試：自行合成一段「長廊」點雲（兩面平行長牆 + 地板），測試 ICP 沿長廊方向的配準是否失準，重現結構退化現象。

討論問題

1. 體素邊長從 0.01 增加到 0.2 公尺，點數減少了幾倍？符合平方關係還是立方關係？為什麼？
2. 點對面 ICP 比點對點快多少？從 17.3 節的原理解釋這個差異。
3. ICP 在初始偏移多大時開始失敗？這對真實機器人系統意味著什麼（提示：里程計與 IMU 的角色）？
4. 長廊測試中，配準在哪個方向失準？這與第 13.6 節的 2D 走廊困境是同一個問題嗎？
5. （大學部）若要為一台校園巡檢機器狗選擇配準方法，你會選 ICP、NDT 還是兩者組合？說明你的理由與場域考量。

延伸挑戰（大學部）

其一：下載一組公開的 3D 光達資料集（如 KITTI 的一段序列），實作一個簡易的光達里程計——連續對相鄰兩幀做配準並累加位姿，把估出的軌跡與真值比較，觀察漂移如何隨距離累積（這正是第 18 章 LOAM 要解決的問題）。其二：若學校有 3D 光達，實際掃描一間實驗室，完成圖 17-4 的完整流程並輸出彩色點雲模型，再用案例 17-1 的「牆厚度」方法評估品質。這份成果可直接作為第 31 章專題二的基礎。

延伸閱讀

1. P. Besl and N. McKay, "A Method for Registration of 3-D Shapes," IEEE TPAMI, 1992. (ICP 的原始論文，第 13、17 章共同的理論源頭)
2. P. Biber and W. Straßer, "The Normal Distributions Transform: A New Approach to Laser Scan Matching," IROS, 2003. (NDT 的原始論文)

3. Q.-Y. Zhou, J. Park, and V. Koltun, "Open3D: A Modern Library for 3D Data Processing," arXiv, 2018. (Open3D 的介紹論文，含配準工作流程範例)
4. Point Cloud Library (PCL) 官方教學 (pointclouds.org) . (降採樣、法向量估計、配準的完整範例)
5. Open3D 官方文件與 Python 教學 (open3d.org) . (本章實作的主要工具，教學友善)
6. A. Hornung et al., "OctoMap: An Efficient Probabilistic 3D Mapping Framework Based on Octrees," Autonomous Robots, 2013. (3D 佔據格地圖的代表作，呼應 17.5 節)
7. X. Li et al., "A Tutorial Review on Point Cloud Registrations: Principle, Classification, Comparison, and Technology Challenges," Mathematical Problems in Engineering, 2021. (點雲配準的完整綜述，含各種降採樣策略比較)

小結

1. 3D 點雲是由大量三維點構成的集合，可附帶反射強度、顏色、線號與時間戳記；它具有無序、稀疏不均、資料量龐大三大特性，且無法像佔據格地圖那樣區分「確定空」與「未知」。
2. 體素降採樣把空間切成立方格，每格以重心作為代表點，能大幅減量並使分布均勻；取重心比取中心精確，近似版本可能產生虛假點。體素邊長應略小於關心的最小特徵尺寸。
3. ICP 以「找對應—求變換—迭代」配準點雲，靠 KD 樹加速最近鄰搜尋；點對面 ICP 因只懲罰垂直表面的偏離而收斂較快，是實務首選。三大限制為需要好初值、怕結構退化、對離群點敏感。

4. NDT 把目標點雲轉成體素內的高斯分布，形成連續可微的機率場，不需搜尋對應點；它比 ICP 快、對初值較不敏感，但精度略低，關鍵參數是體素解析度，須依場景尺度調校。
5. 3D 地圖有三種表示：原始點雲（保真度高）、八叉樹佔據格（能區分三態、適合導航）、網格模型（檔案小、適合展示）；室內掃描流程為規劃路線、採集、前處理、配準、全域最佳化、後處理輸出。
6. 點雲顏色化以第 9 章的相機投影模型，把影像 RGB 賦予三維點，關鍵在精確的內外參與時間同步；彩色點雲提升可讀性、提供語意線索，並用於文化資產保存與缺陷檢測。
7. 3D 建模應用於工廠數位分身、校園測繪與導航地圖、展場與古蹟保存；光達不受照明影響的特性使其在低光與無紋理場域勝過相機，而邊緣運算平台的進步已讓 3D SLAM 走出工作站。

本章備齊了三維點雲的處理工具：降採樣、配準、地圖表示與顏色化。但把相鄰掃描逐幀配準累加，誤差仍會隨距離累積——這正是第 7 章漂移問題的三維版本。下一章的 LOAM 給出了漂亮的解答：它不對所有點做配準，而是聰明地提取「邊緣特徵」與「平面特徵」，並用「高頻里程計 + 低頻建圖」的雙層架構，在即時性與精度之間取得絕佳平衡。這是自主巡檢機器人與自駕車 3D 定位的技術骨幹。

台灣自編大學教科書

@prof

《地圖建構與同步定位》

Simultaneous Localization and Mapping, SLAM

第 18 章

LOAM 與光達里程計

編者：李世淵（機器人叫獸）

助教：李天宇、李宇晴

大學智慧機器人學程 / 高中 AI 機器人社團課程

本章在全書的位置

第 17 章把點雲處理的工具備齊了，但也留下一個尷尬：ICP 與 NDT 都要花時間在「找對應」上，而一幀 3D 掃描動輒數萬點，逐幀配準再累加，既慢又會持續漂移。本章的 LOAM 給出的答案聽起來幾乎像是取巧——不要用全部的點，只用百分之二三的「有特色」的點。但這個取巧背後有嚴謹的幾何理由，而理解那個理由，就是理解整個第五篇的鑰匙。

本章的結構呼應了 LOAM 的兩大貢獻。18.2 節談「挑哪些點」，用的是曲率這把量尺；18.3 節談「怎麼安排運算」，用的是高頻 / 低頻雙層架構——同學會發現它與第 15 章 Cartographer 的「局部 SLAM + 全域 SLAM」是同一個設計哲學在不同維度的化身。18.4 之後則是這套架構的後代與應用，一路通到第七篇的巡檢專題。

圖 18-0 第 18 章的連結地圖

前面累積的工具

第 7 章 IMU 第 12 章 最小平方 第 15 章 雙層架構



【第 18 章 LOAM：只用 2% 的點就夠了】

曲率特徵－邊緣 / 平面互補－雙層架構－運動補償



LeGO-LOAM－LIO-SAM－Fast-LIO (光達慣性緊耦合)



第六篇 視覺 SLAM 第七篇 巡檢與場域應用

學習目標

上一章我們學會了點雲的降採樣與配準，但把相鄰掃描逐幀 ICP 累加，不僅慢、誤差也持續累積。LOAM 給出了漂亮的解答——不對所有點做配準，而是聰明地提取邊緣與平面特徵，

並用「高頻里程計 + 低頻建圖」的雙層架構取得即時性與精度的平衡。這是自主巡檢機器人與自駕車 3D 定位的技術骨幹。學完本章之後，同學應能夠達成下列目標：

1. 說明 LOAM 的核心問題與它在 3D 光達 SLAM 發展史上的地位。
2. 說明如何以曲率（粗糙度）判別邊緣特徵與平面特徵，以及為何只用特徵點就能配準。
3. 解釋高頻里程計與低頻建圖的雙層架構，以及它為何能兼顧即時性與精度。
4. 比較 LeGO-LOAM、LIO-SAM、Fast-LIO 等後續系統的改良重點。
5. 說明光達與 IMU 緊耦合的動機、優勢與實作要點。
6. 說明 3D SLAM 如何應用於自主巡檢機器人。
7. 規劃一個以大學場域為對象的巡檢專題（走廊、電梯、實驗室）。

核心概念

中文名詞	英文名詞	概念說明
光達里程計與建圖	LOAM	以邊緣與平面特徵進行即時光達定位建圖的經典方法。
光達里程計	LiDAR Odometry	僅由連續光達掃描推算機器人運動的技術。
曲率 / 粗糙度	Curvature / Smoothness	衡量一點周圍局部起伏程度的指標，用來分類特徵。
邊緣特徵	Edge Feature	曲率高的點，位於角落、柱子、樹幹等尖銳處。
平面特徵	Planar Feature	曲率低的點，位於牆面、地面等平坦處。
點到線距離	Point-to-Edge Distance	邊緣特徵配準時使用的誤差量。
點到面距離	Point-to-Plane Distance	平面特徵配準時使用的誤差量。
運動變形	Motion Distortion	光達旋轉期間載具移動造成同一幀點雲扭

中文名詞	英文名詞	概念說明
		曲。
地面分離	Ground Segmentation	把地面點與非地面點分開處理，LeGO-LOAM 的關鍵。
兩步最佳化	Two-step Optimization	先由地面平面解部分自由度，再由邊緣解其餘自由度。
光達慣性里程計	LIO	光達與 IMU 緊耦合的里程計方法。
迭代擴展卡爾曼濾波	iEKF	Fast-LIO 採用的高效緊耦合估測架構。

18.1 LOAM : LiDAR Odometry and Mapping

LOAM 由 Ji Zhang 與 Sanjiv Singh 於 2014 年在 CMU 機器人研究所提出，論文標題為「LOAM: Lidar Odometry and Mapping in Real-time」。它是 3D 光達 SLAM 領域影響最深遠的一篇工作——後續幾乎所有主流系統都建立在它的思想之上。

它要解決的問題

第 17 章末尾留下一個難題：把相鄰的 3D 掃描逐幀用 ICP 配準再累加，會遇到兩個瓶頸。其一是速度——每幀數十萬點，ICP 的最近鄰搜尋負擔沉重，難以即時。當掃描包含大量點時，ICP 可能承受過高的計算成本。其二是精度——逐幀累加，誤差持續漂移。

LOAM 的核心洞見是：不需要用上所有的點。環境中真正提供幾何約束的，是那些「有特色」的點——牆角、柱子、樹幹（邊緣），以及牆面、地面（平面）。只要抓住這些特徵點來配準，就能用不到原始點數百分之一的資料量，達到相當甚至更好的精度。

LOAM 的兩大貢獻

- 特徵提取：以曲率（粗糙度）把點分為邊緣特徵與平面特徵，大幅減少參與運算的點數（18.2 節）。
- 雙層架構：把問題拆成「高頻但粗略的里程計」與「低頻但精確的建圖」兩個並行任務，兼顧即時性與精度（18.3 節）。

LOAM 把 SLAM 問題拆成兩個平行任務——里程計與建圖——並藉由從光達掃描中提取邊緣與平面特徵、在長期最佳化中處理特徵對應，在結構化環境中以低運算成本達成高精度。這個「特徵提取 + KD 樹對應搜尋」的架構，已被後續大量光達里程計研究採用為核心流程。

歷史地位

自 Zhang 與 Singh 提出 LOAM 以來，以光達為基礎的 SLAM 研究快速推進；LOAM 以曲率提取邊緣與平面特徵，並透過與 KD 樹的掃描對地圖匹配估計 6 自由度位姿，藉由把

里程計與建圖分離到不同的執行頻率，同時達成運算效率與精度。

對本書讀者而言，理解 LOAM 就等於掌握了整個第五篇的鑰匙：第 18.4 節的 LeGO-LOAM、LIO-SAM、Fast-LIO 全都是它的後代，而大學自主巡檢機器人的相關研究，也以這條技術脈絡為基礎。

18.2 邊緣特徵與平面特徵

本節是 LOAM 最具識別度的設計：如何從數十萬點中，挑出少數真正有用的特徵點。

曲率：判別特徵的量尺

LOAM 用一個簡單而巧妙的指標來分類每個點——局部粗糙度（常稱為曲率）。做法是：取某個點與它在同一條掃描線上的鄰居們，計算「這個點偏離鄰居平均位置的程度」。

- 粗糙度高：表示這個點與周圍鄰居的排列不共線，位於尖銳處——這是邊緣特徵。


典型例子：牆角、柱子邊、樹幹、桿件。

- 粗糙度低：表示這個點與鄰居近乎排成一直線，位於平坦處——這是平面特徵。典

型例子：牆面、地面、天花板、大型平板。

每一幀點雲中，只需挑出粗糙度最高的少數點作為邊緣特徵、最低的少數點作為平面特徵。LeGO-LOAM 論文中的圖示清楚展示了這個過程：原始點雲經分割後，以藍色與黃色分別標示邊緣與平面特徵。

圖 18-1 曲率這把量尺：從一條掃描線到少數幾個特徵點



這張圖來自一次真實的模擬：一條寬 7 公尺、長 80 公尺的走廊，沿途有柱列、門框與一根方柱，用 32 線光達掃描一幀，得到 32,603 個有效點。圖(a) 取其中一條掃描線，把公式一算出的曲率沿方位角畫出來（縱軸為對數刻度）。整條曲線絕大部分時間都在 10^{-3} 附近低吟——那是平坦的牆面；而每當掃到柱子或門框，曲線就出現一根尖峰，瞬間躍升兩個數量級。

圖(b) 把全幀所有點的曲率畫成直方圖，可以看到一個單峰分布，峰值落在 10^{-3} 左右。LOAM 要的不是這個峰，而是分布的「兩端」：右端尾巴（曲率高）是邊緣特徵，左端尾巴（曲率低）是平面特徵。中間那一大坨佔了絕大多數的點，對配準幾乎沒有額外貢獻——這就是案例 18-1 所說「大部分點是冗餘的」最直接的視覺證據。

圖(c) 驗證了這套篩選是否真的挑到對的東西。紅色菱形是邊緣特徵，可以看到它們準確地落在金圈標出的柱子上，以及門框與方柱的位置；藍色小點是平面特徵，均勻鋪在兩側長牆與地面上。最後的數字是：邊緣 61 個、平面 384 個，合計僅佔原始點數的 2.7%。換句話說，LOAM 丟掉了 97% 的資料，而丟掉的那些，正是提供不了新資訊的那些。

本書也實測了這個減量的代價。在同一組掃描上，用全部 32,513 點做點對面配準，角誤差 0.031 度、位移誤差 1.1 公釐、耗時 0.18 秒；只用 768 個平面特徵（2.4%），角誤差 0.042 度、位移誤差 1.3 公釐、耗時 0.038 秒。精度幾乎沒有損失，時間卻降到五分之一。這就是 LOAM 能夠「即時」的根本原因。

曲率門檻與那兩道剔除

本圖的門檻取邊緣 $c > 0.08$ 、平面 $c < 0.015$ ，並限制每條掃描線的每個子區段最多取 2 個邊緣、4 個平面點，避免特徵擠在同一處（18.2 節的「均勻分布」）。

LOAM 原論文另有兩道剔除，本圖也實作了：一是遮擋邊界點（相鄰距離跳變處，較遠一側其實是被擋住的，下一幀就會變樣）；二是掃描線近乎平行於表面的點（量測極不穩定）。

剔除比例約 8%。少了這兩道，遠處牆面因量測雜訊造成的假尖峰會被誤判成邊緣特徵，本書初次實作時正是如此——邊緣點散落在空牆上，而不是柱子上。

門檻需隨光達線數與場域調整。線數越少、角解析度越粗，曲率的雜訊就越大，門檻要放寬。


為什麼兩種特徵都需要

這是本節最重要的觀念。兩種特徵提供的幾何約束互補：

- 平面特徵約束「垂直於平面的移動」。一面牆能告訴你「你離牆多遠」，但無法告訴你「你沿著牆走了多遠」——沿牆滑動時，平面約束完全不變。
- 邊緣特徵約束「垂直於邊緣的移動」。一根柱子能鎖定你在水平兩個方向的位置，但沿柱子上下移動它管不著。

把兩者結合，才能鎖定完整的六個自由度。這也解釋了第 17.3 節提到的結構退化：在長廊中，牆面提供的都是「同方向的平面約束」，而缺乏沿走廊方向的邊緣特徵，沿廊方向的位移因而無法確定。

圖 18-2 為什麼兩種特徵缺一不可：鎖住的方向正好互補



這是本章最重要的觀念，而它可以被精確地量化。做法是把配準誤差對位姿的敏感度寫成一個「資訊矩陣」——某個方向上的資訊量越大，代表只要往那個方向偏一點，誤差就會明顯上升，也就是那個方向被鎖得越緊。圖(a)先給出幾何直覺：一面牆只能鎖住垂直於牆的那一個方向，沿著牆面滑動它完全不受懲罰；一根柱子則鎖住水平的兩個方向，但沿著柱子上下滑動它管不著。

圖(b)是實測。只用平面特徵時，沿走廊方向的資訊量是 0.157，橫向 0.430、垂直 0.413——沿走廊明顯是最弱的一環。只用邊緣特徵時情況恰恰相反：水平兩個方向分別是 0.980 與 0.994，幾乎滿格，而垂直方向只有 0.026，等於沒有約束。兩組數字的形狀互為補集，這正是 18.2 節那句「兩種特徵提供的幾何約束互補」的量化版本。

圖(c)則把結論推到極端，順便回答了第 17 章留下的問題。把走廊裡的柱子與門框全部移除，變成一條純粹的空長廊，重新計算：平面特徵沿走廊方向的資訊量只剩 0.011，而橫向 0.470、垂直 0.518——相差超過四十倍。更說明問題的是，在這條空長廊裡，曲率篩選找到的邊緣特徵數量是零：環境裡根本沒有任何尖銳結構可以提供沿軸向的約束。

這就是第 17.3 節「結構退化」在 LOAM 框架下的精確描述：不是演算法不夠好，而是幾何資訊本身不存在。而一旦把柱列加回去，邊緣特徵立刻出現 26 個，平面特徵沿走廊的資訊量也從 0.011 升到 0.157（門框與方柱貢獻了垂直於走廊的面）。這也預告了 18.5 節的結論——當環境本身提供不了約束時，唯一的辦法是從別的感測器拿，而 IMU 正是那個來源。

怎麼讀「資訊量」這個數字

它是每個特徵點平均提供的約束強度，無單位，介於 0 與 1 之間。1 代表該方向被完全鎖住，0 代表完全自由。

平面特徵的資訊矩陣是 $\Sigma \mathbf{n} \mathbf{n}^T$ ($\mathbf{n}$ 為表面法向量)：法向量指向哪，就鎖住哪個方向。

邊緣特徵的資訊矩陣是 $\Sigma (\mathbf{I} - \mathbf{u} \mathbf{u}^T)$ ($\mathbf{u}$ 為邊緣方向)：鎖住所有垂直於邊緣的方向。

本圖中柱子都是鉛直的，所以 $\mathbf{u}$ 幾乎都是 z 軸，鎖住的就是水平面。

這個分析也是現代系統「退化偵測」的基礎：即時算出資訊矩陣的最小特徵值，一旦低於門檻就知道自己正走進退化場景，可以提高對 IMU 的信任（見 18.8 節）。

均勻分布：避免特徵集中

LOAM 還有一個實務細節：把每條掃描線分成數個子區段，在每個子區段中各挑選一定數量的特徵點。這確保特徵均勻分布於整個視野，而不會全部集中在某個角落——特徵若集中在一側，配準的幾何條件會很差（這與第 5 章 GNSS 的 DOP 概念異曲同工）。

配準的誤差定義

特徵提取後，配準的方式也隨特徵類型而不同：

- 邊緣特徵：在上一幀（或地圖）中找出對應的邊緣（由兩個鄰近的邊緣點決定），誤差定義為「點到這條線的垂直距離」。
- 平面特徵：在上一幀（或地圖）中找出對應的平面（由三個鄰近的平面點決定），誤差定義為「點到這個平面的垂直距離」。

把所有特徵點的誤差平方和最小化，就得到最佳的位姿變換——這又是第 12 章的非線性最小平方問題。同學應該能感受到：第三篇的數學工具，在每一個具體系統中反覆現身。

18.3 高頻里程計與低頻地圖最佳化

LOAM 的第二項核心創新，是把 SLAM 拆成兩個並行運行、頻率不同的任務。這個架構設計極為經典，值得同學仔細理解。

兩個任務的分工

- 光達里程計（高頻）：比較相鄰兩幀掃描的特徵，快速估出「這 0.1 秒我移動了多少」。它只用兩幀資料，運算輕、速度快，但精度較低、會漂移。
- 光達建圖（低頻）：把當前掃描與「累積的全域地圖」比對，做更精細的配準。地圖包含大量歷史資訊，配準更準，但運算重、頻率低。

在 LOAM 的原始設計中，建圖模組以 1 Hz 的頻率把點雲投影到地圖上；最後，兩個演算法發布的位姿變換被整合起來，產生約 10 Hz 的輸出，代表光達相對於地圖的位姿。

圖 18-3 LOAM 的雙層架構

【光達里程計】高頻（約 10 Hz）

相鄰兩幀特徵匹配 → 快速估出相對運動

特性：即時、輕量、精度較低、會漂移

↓ 提供運動估計與初始猜測

【光達建圖】低頻（約 1 Hz）

當前掃描 ↔ 全域地圖特徵匹配 → 精細配準

特性：精確、運算重、頻率低

↓

【位姿整合】

把兩者的變換整合 → 輸出約 10 Hz 的高頻且精確位姿

為什麼這樣設計是聰明的

這個架構的精妙之處，在於它讓「即時性」與「精確性」不再互相衝突：

1. 高頻里程計滿足即時控制的需求。機器人的運動控制迴路需要高頻位姿，不能等 1 秒才更新一次。
2. 低頻建圖負責消除漂移。它有充裕的時間做精細配準，把高頻里程計累積的誤差拉回來。
3. 高頻里程計為低頻建圖提供良好的初始猜測。這正是第 17.3 節強調的——ICP 類方法需要好的初值才能收斂，而里程計恰好提供了它。


同學應該注意到：這個「快速但粗略的前端 + 緩慢但精確的後端」架構，與第 15 章 Cartographer 的「局部 SLAM + 全域 SLAM」雙子系統如出一轍。這不是巧合，而是機器人系統設計的一個普遍模式：用不同的時間尺度處理不同性質的問題。

運動變形補償

還有一個 3D 光達特有的問題必須處理。機械式光達旋轉一圈需要約 0.1 秒 (10 Hz)，在這段時間內，載具本身也在移動。結果是：同一「幀」點雲中的各個點，其實是在不同位置量到的——點雲因此被扭曲，稱為運動變形 (Motion Distortion，第 8.4 節提過)。

LOAM 的處理方式是：利用里程計估出的運動，把每個點依其量測時刻反推回「幀起始時刻」的座標系，消除變形。這正是第 17.1 節提到「點雲需要時間戳記」的原因。後續系統如 LIO-SAM 也明確要求：當光達以 10 Hz 旋轉時，每個點的時間戳記應在 0 到 0.1 秒之間變化。

圖 18-4 運動變形：光達轉一圈的時間裡，車子也在動



機械式光達轉一圈約需 0.1 秒，而在這 0.1 秒內載具本身也在移動與轉向。結果是：同一「幀」點雲裡的點，其實是在不同位姿下量到的。若天真地把它們全部當成同一時刻、同一位姿的量測，整片點雲就會被扭曲。圖(a) 是這個現象的模擬：載具以 6 公尺 / 秒前進、同時以 1.6 弧度 / 秒轉彎，淺灰色是真實幾何、紅色是未補償的點雲——兩側長牆明顯被拉斜，平均每點偏離真實位置 0.570 公尺。

圖(b) 是補償之後。做法正是 18.3 節所述：以等速度模型推算每個點量測時刻的位姿，把它反推回「幀起始時刻」的座標系。藍色點雲與灰色真值完全重合，平均誤差回到零。這裡要誠實說明：之所以能回到零，是因為補償用的速度正好等於模擬時使用的速度——這是理想狀況，用來驗證補償公式本身沒有寫錯。

真正有意思的是圖(c)。紅線是完全不補償時的平均點位誤差，它與速度成正比：1 公尺 / 秒時 0.062 公尺，6 公尺 / 秒時 0.405 公尺。黃線與藍線則是速度估計分別有 30% 與 10% 誤差時的殘餘誤差。三條線呈現一個乾淨的比例關係：補償後的殘餘誤差，大約等於「速度估計的誤差百分比」乘上「完全不補償時的誤差」。速度估計差 10%，殘餘誤差就是不補償時的 10%。

這條比例關係把 18.3 與 18.5 兩節扣在一起。它說明運動補償的品質完全取決於速度估計的品質，而速度估計正是 IMU 最擅長的事——數百赫茲的更新率，短時間內極為精確。這就是為什麼現代的光達系統幾乎都要配 IMU：不只是為了配準的初值，也是為了讓每一幀點雲在進入配準之前，就已經是一片沒有變形的乾淨資料。

運動變形的三個實務重點

速度越快、轉得越急，變形越嚴重；其中「轉」比「直行」影響更大，因為旋轉會讓遠處的點產生與距離成正比的位移。本圖在 6 m/s 時最大單點誤差達 2.36 公尺。

補償需要每個點的時間戳記。這正是第 17.1 節提到的「時間戳記」欄位的用途，也是案例 18-3 所說「缺少必要欄位就跑不起來」的原因之一。

固態光達沒有旋轉機構，但掃描仍需時間，一樣有變形問題，只是模式不同。

等速度模型是最簡單的假設。急加速或急轉彎時它會失準，這時 IMU 提供的實測角速度與加速度就比模型推算更可靠。

18.4 LeGO-LOAM、LIO-SAM、Fast-LIO 簡介

LOAM 開創了道路，後續十餘年間出現了大量改良系統。本節介紹三個最具代表性的後代，它們各自解決了 LOAM 的不同弱點。

一、LeGO-LOAM：輕量化與地面最佳化

LeGO-LOAM 全名為「輕量化且地面最佳化的光達里程計與建圖」，針對地面載具的即時 6 自由度位姿估計而設計。它輕量，能在低功耗嵌入式系統上達成即時位姿估計；它地面最佳化，因為它在分割與最佳化步驟中善用了地平面的存在。

它的兩項關鍵改良是：

- 點雲分割與地面分離：先進行點雲分割以濾除雜訊，再做特徵提取以取得具鑑別度的平面與邊緣特徵。分割能有效去除植被、雜訊等不穩定的點——這對戶外環境特別重要。
- 兩步最佳化：採用兩步驟的 Levenberg-Marquardt 最佳化，用平面與邊緣特徵分別求解 6 自由度變換的不同分量。具體而言，先用地面點提取的平面特徵求出垂直位移

與滾轉、俯仰角，再用分割後點雲的邊緣特徵估計水平位移與偏航角，並以前一步的結果作為約束。

實測顯示，LeGO-LOAM 在多變地形的地面載具資料集上，能以更低的運算成本達到與 LOAM 相當或更好的精度。它特別針對水平放置於地面載具上的 16 線光達最佳化，並假設掃描中總是存在地平面——這個假設限制了它的適用範圍，但也正是它高效的原因。

二、LIO-SAM：光達慣性緊耦合與因子圖

LIO-SAM 的創新在於以因子圖搭配貝氏樹進行 IMU 緊耦合，實現具運動感知的子地圖匹配，並整合考量漂移的閉環偵測。

- 緊耦合 IMU：把 IMU 預積分（第 7 章）作為因子加入圖中，大幅提升在快速運動下的穩健度。
- 因子圖架構：採用第 12 章介紹的 GTSAM 與 iSAM2 增量式求解，能高效地融合光達、IMU、GPS 與閉環等多種約束。
- 閉環偵測：其閉環功能改編自 LeGO-LOAM，是基於 ICP 的方法；由於 ICP 執行較慢，官方建議測試時把播放速度設為原速。

值得注意的實作限制：與原始 LOAM 實作相同，LIO-SAM 只能搭配九軸 IMU（能提供滾轉、俯仰與偏航估計），且目前僅支援機械式光達。這類細節在專題實作時非常關鍵，同學選用硬體前務必確認。

三、Fast-LIO 系列：效率的極致

Fast-LIO 走的是另一條路線：不做特徵提取，直接使用原始點雲，並以迭代擴展卡爾曼濾波（iEKF）進行緊耦合估測。它的關鍵創新是一種高效的卡爾曼增益計算公式，使運算複雜度與狀態維度而非量測數量相關，大幅提升速度。

Fast-LIO2 進一步引入增量式 KD 樹（ikd-Tree）資料結構，能高效地增量更新地圖，達成極高的處理頻率，特別適合運算資源受限的平台與快速運動的載具（如無人機）。這條

路線證明了：在 IMU 提供良好運動先驗的前提下，不做特徵提取也能又快又準。

系統	年份	關鍵改良	適用場景
LOAM	2014	特徵提取 + 雙層架構	通用，奠基之作
LeGO-LOAM	2018	地面分離、兩步最佳化、輕量化	地面載具、嵌入式平台
LIO-SAM	2020	IMU 緊耦合、因子圖、多源融合	需高穩健度與閉環的場域
Fast-LIO2	2021	免特徵、iEKF、增量式 KD 樹	運算受限平台、快速運動

表 18-1 LOAM 系列主要系統比較

18.5 光達 + IMU 緊耦合

第 18.4 節的三個系統中，有兩個都在強調 IMU。本節說明為什麼光達 SLAM 越來越離不開 IMU，以及緊耦合的意義。

光達單獨使用的三個弱點

- 快速運動下失效：純光達方法在快速動態運動下表現會劣化；掃描之間差異太大，配準難以收斂（第 13.3 節 ICP 需要好初值的老問題）。
- 幾何退化環境：在長走廊或開闊空間等幾何退化的環境中，不足的幾何約束會導致位姿估計失敗。這是第 17.3 節結構退化的再次出現。
- 運動變形：如 18.3 節所述，旋轉期間的載具運動會扭曲點雲，需要運動資訊才能補償。

IMU 恰好補上這三個缺口

回顧第 7 章：IMU 更新率極高（數百 Hz）、短時間內極為精確、完全不受環境結構影響。它恰好能：

1. 在兩幀光達之間提供高頻運動估計，作為配準的優良初值，解決快速運動問題。

2. 在幾何退化的方向上提供獨立的約束——走廊裡光達說不清「走了多遠」，IMU 的加速度積分卻能給出估計。
3. 提供每個點量測時刻的精確姿態，用於運動變形補償。

反過來，光達也回報 IMU 它最需要的東西：不漂移的位姿觀測，用來持續估計並補償 IMU 的零偏（第 7.3 節）。光達慣性里程計（LIO）因而受到高度重視，它緊密融合光達量測與 IMU 資料，結合了光達對光線變化的穩健性與捕捉稠密幾何資訊的能力。

鬆耦合 vs 緊耦合

第 7.6 節在視覺慣性 SLAM 中討論過這組概念，在光達領域完全適用：

- 鬆耦合：光達 SLAM 與 IMU 各自算出位姿，再加權融合。實作簡單，但資訊已被壓縮，精度受限。
- 緊耦合：把 IMU 預積分約束與光達特徵配準誤差，放進同一個最佳化問題（或同一個濾波器）一起求解。精度顯著較佳，是現代系統的一致選擇。

LIO-SAM 以因子圖實現緊耦合（最佳化路線，第 12 章）、Fast-LIO 以 iEKF 實現緊耦合（濾波路線，第 11 章）——兩者殊途同歸，再次印證第 11、12 兩章正是 SLAM 的兩條主幹。

實作要點

- 時間同步：光達與 IMU 的時間戳記必須精確對齊，誤差幾毫秒就會顯著影響精度（第 5、10 章反覆強調的工程細節）。
- 外參校正：IMU 與光達的相對安裝位置與姿態必須準確量測（第 10 章的外參），否則融合結果會系統性偏差。
- IMU 規格：如前所述，部分系統要求九軸 IMU。此外 IMU 的品質（第 7 章的等級表）直接影響在退化場景中能撐多久。

18.6 自主巡檢機器人的 3D SLAM

3D 光達 SLAM 最重要的實際應用之一，就是自主巡檢機器人。本節說明這類系統的需求與設計考量。

為什麼巡檢需要 3D 而非 2D

- 地形起伏：巡檢機器人（尤其是機器狗）需要上下樓梯、跨越門檻、走過斜坡。2D 地圖無法描述高度變化，也無法判斷「這個台階跨得過去嗎」。
- 立體障礙：工廠的懸空管線、機房的機櫃上緣、樹枝，都不在 2D 掃描平面上。第 8 章的高度盲區在巡檢場域會直接造成碰撞。
- 巡檢目標的三維位置：要記錄「三樓東側牆面第二根管線有鏽蝕」，需要三維座標而非平面位置。
- 資產建模：巡檢的副產品往往是設施的三維模型（第 17.7 節的數位分身），本身就有價值。

典型系統架構

圖 18-5 自主巡檢機器人的 3D SLAM 系統架構

【感測層】3D 光達 + IMU + (可選) 相機、GNSS、輪速計



【前端】特徵提取 (邊緣 / 平面) 或直接點雲配準



【緊耦合估測】LIO：光達約束 + IMU 預積分 → 高頻 6-DoF 位姿



【後端】因子圖最佳化 + 閉環偵測 (第 12 章)



【地圖】3D 點雲地圖 → 轉八叉樹供導航使用 (第 17.5 節)



【應用層】路徑規劃、避障、巡檢點導航、影像/熱像資料採集

平台選擇：輪型、履帶、四足

- 輪型：效率最高、續航最好，但受限於平坦地面，無法上樓梯。適合工廠平面與走廊巡檢。
- 履帶型：可跨越較大障礙與斜坡，常見於災害現場與戶外巡檢。
- 四足（機器狗）：地形適應力最強，能上樓梯、跨障礙，是近年巡檢的熱門選擇。代價是續航較短、成本高，且劇烈的步態震動對 SLAM 是嚴峻考驗——這正是必須用 IMU 緊耦合的原因。

巡檢任務的特殊需求

- 重複性：巡檢是週期性任務，同一條路線每天走。因此「首次建圖、後續定位」的模式特別適用（第 14 章案例 14-3），且能比較不同時間的資料找出變化（例如新出現的裂縫）。
- 精確定位到巡檢點：機器人需要停在特定位置、以特定角度拍攝儀表或設備。定位誤差需控制在數公分，這是 3D SLAM 精度要求的來源。
- 長時間運行：巡檢任務可能持續數小時，對漂移控制與系統穩定性要求極高——閉環偵測因此不可或缺。
- 資料關聯：巡檢採集的影像、熱像、聲音資料，都需要標上精確的三維位置，才能在數位分身中定位問題。

18.7 LOAM 之後：2024–2026 年光達慣性里程計的四個走向

LOAM 發表於 2014 年，十餘年來它的兩大設計——特徵提取與雙層架構——一直是光達 SLAM 的標準骨架。但近兩年，這兩根支柱都受到了認真的挑戰，而挑戰的方向恰好都指向同一件事：運算資源變便宜了，所以當年為了即時性所做的妥協，現在未必還划算。本節整理四個走向。

一、特徵提取正在被放棄

第一個走向是 18.4 節介紹 Fast-LIO 時已經埋下的伏筆：不做特徵提取，直接用原始點雲。這條路線在近年幾乎成為主流。理由很現實——2014 年提取特徵是為了把數十萬點降到數千點，否則算不動；但在今天的處理器與 GPU 上，直接拿幾萬點做體素化的配準已經完全可行，而且少了特徵提取這一步，就少了一組需要調整的門檻，也少了「柱子太細被漏掉」這類失效模式。

這與第 17.8 節提到的 KISS-ICP 是同一股風潮：與其設計精巧的篩選規則，不如把最基本的配準做紮實。不過本章圖 18-2 的分析仍然沒有過時——免特徵的方法一樣要面對幾何退化，只是它不再用「邊緣 / 平面」這組語彙來描述，而是直接看體素分布的共變異數。概念是同

一個，換了個說法。

二、全域一致性回到前台：GLIM

第二個走向是對「雙層架構」本身的修正。LOAM 的低頻建圖雖然會修正漂移，但前端一旦把某一幀的位姿定下來，就不再回頭。產業技術總合研究所 Kenji Koide 團隊於 2024 年發表於《Robotics and Autonomous Systems》的 GLIM，主張這個「定下來就不改」的設計正是退化場景下崩潰的根源。

GLIM 的做法有兩個關鍵：其一是在里程計端採用固定延遲平滑（五秒視窗），讓最近幾秒的位姿持續被修正，而不是立即定案；其二是全域最佳化時直接最小化子地圖之間的配準誤差，而不是先把它們壓縮成位姿圖上的高斯約束。再加上 GPU 加速的體素化 GICP，整套系統在一般配備下每幀前處理 15.1 毫秒、里程計 29.3 毫秒。

效果在退化場景最明顯。該論文以固態光達在八段退化序列上測試，GLIM 的絕對軌跡誤差落在 0.017 到 0.389 公尺之間，而 FAST-LIO2 的範圍是 0.297 到 15.551 公尺——最差的一段差了四十倍。這個對比值得同學記住：在條件良好時各家系統差距不大，真正拉開差距的永遠是最壞情況。

三、退化不再只是被動承受，而是主動偵測

第三個走向直接承接本章圖 18-2 的分析。既然退化可以用資訊矩陣的最小特徵值量化，那就可以即時算出來：一旦發現某個方向的約束不足，系統就自動降低對光達的信任、提高對 IMU 的權重，甚至在該方向上乾脆不更新。這類「退化感知」的光達慣性里程計是 2025 年前後相當活躍的題目。

對專題而言，這提供了一個門檻不高但很有價值的方向：不必自己寫一套完整的 LIO，只要在既有系統上加一個資訊矩陣的監看器，把最小特徵值隨時間畫出來，再對照機器人實際走過的場域，就能做出一份「這棟建築哪裡會讓 SLAM 失效」的地圖。這對第 19 章的巡檢專題直接有用。

四、從光達慣性到光達慣性視覺

第四個走向是把相機也拉進同一個緊耦合框架。FAST-LIVO2 一類的系統在 Fast-LIO 的迭代卡爾曼濾波架構上，再加入影像的直接光度誤差，形成光達、慣性、視覺三者的緊耦合。動機與第二篇的感測器互補分析完全一致：光達給幾何、相機給紋理與語意、IMU 給高頻運動，三者的失效模式幾乎不重疊。

特別值得注意的是它對退化場景的意義。長走廊讓光達說不清「走了多遠」，但牆上的海報、門牌、地板紋理對相機而言是清楚的特徵——這正好補上圖 18-2(c) 裡那個 0.011 的空缺。換句話說，第六篇即將介紹的視覺 SLAM，不只是另一條平行的路線，也是本章這套系統在退化場景下的救援方案。

四個走向的共同線索

運算面（免特徵）：當年為即時性而做的篩選，在今天的硬體上未必划算。

架構面（GLIM）：前端不該把位姿立刻定死，保留修正空間才撐得過退化區段。

診斷面（退化感知）：退化從「事後才發現的災難」變成「可即時量測的指標」。

感測面（光達慣性視覺）：單一感測器補不了的洞，就用失效模式不重疊的另一種來補。

共同線索：本章的曲率、互補約束與運動補償三樣基本功沒有被淘汰，它們反而成了判斷新系統好壞的標準——任何新方法都要回答同樣的三個問題：哪些點有用、哪個方向沒約束、以及掃描期間車子動了多少。

承先啟後

本章完成了 3D 光達 SLAM 的核心技術。從第 17 章的點雲處理到本章的 LOAM 系列，同學已經具備在三維世界中定位建圖的完整知識：圖 18-1 說明哪些點值得留下，圖 18-2 說明為什麼兩種特徵缺一不可，圖 18-4 說明掃描期間的運動必須被補償。這三件事也正是所有後續系統——LeGO-LOAM、LIO-SAM、Fast-LIO、GLIM——各自改良的起點。

但圖 18-2(c) 那個 0.011 的數字，是本章無法靠自己解決的問題：當環境的幾何本身提供不了約束，再好的光達演算法也變不出資訊。18.5 節給了第一個答案——IMU，而第六篇將給出第二個答案——相機。

在那之前，下一章要先回答另一個問題：這些技術放進一台每天要跑一年的機器人裡，會遇到什麼？第 19 章把 3D SLAM 帶進自主巡檢的場域，處理巡檢點排序、重複定位精度與長期地圖維護這三件「演算法課本不教、但決定系統成敗」的事——而本章圖 18-2 的退化分析，到了那裡會變成某個巡檢點每兩次就拍歪一次的具體後果。

公式或流程

一、局部粗糙度 (曲率)

對第 i 個點 p_i ，取同一掃描線上鄰近的點集合 S ，其粗糙度定義為：

$$c = (1 / (|S| \cdot \|p_i\|)) \cdot \sum_{p_j \in S} \|p_i - p_j\|$$

式子的意義是：把 p_i 與所有鄰居的位置差向量加總。若 p_i 位於平坦處，左右鄰居的差向量會互相抵消， c 值很小；若位於尖角，差向量同向疊加， c 值很大。分母的 $\|p_i\|$ 用來正規化距離的影響（遠處點間距大，不應因此被誤判為邊緣）。

- c 大於門檻 → 邊緣特徵
- c 小於門檻 → 平面特徵

二、點到線與點到面的距離

邊緣特徵的誤差為「點到對應邊線的垂直距離」。設當前邊緣點為 p ，對應邊線由地圖中兩點 a 、 b 決定：

$$d_{edge} = \| (p - a) \times (p - b) \| / \|a - b\|$$

分子是三點構成的平行四邊形面積（以外積計算），除以底邊長即得高——也就是點到直線的距離。

平面特徵的誤差為「點到對應平面的垂直距離」。設平面由地圖中三點 a 、 b 、 c 決定，其法向量 $n = (b - a) \times (c - a)$ ：

$$d_{plane} = | (p - a) \cdot n | / \|n\|$$


三、LOAM 的最佳化目標

把所有特徵點的誤差組合起來，求位姿變換 T 使總誤差最小：

$$T^* = \operatorname{argmin} (\sum d_{edge}(T \cdot p_i)^2 + \sum d_{plane}(T \cdot p_i)^2)$$

這是一個非線性最小平方問題，以 Levenberg-Marquardt 法迭代求解（第 12 章）。同學可以看出：從第 12 章的抽象理論、第 13 章的 2D 掃描匹配、第 17 章的 ICP，到本章的 LOAM，都是同一套數學在不同資料上的應用。

四、LOAM 完整處理流程

圖 18-6 LOAM 每一幀的處理流程**案例****案例 18-1 為什麼只用百分之一的點，反而更準**

初學者聽到 LOAM 「只用少數特徵點配準」時，直覺反應往往是：丟掉這麼多資料，精度不會下降嗎？答案出乎意料——不但不會，往往還更準。

原因有三。其一，大部分點是「冗餘」的：一面平坦的牆上有上萬個點，但它們提供的幾何約束其實只有一個——「你離這面牆多遠」。用一萬個點或一百個點來表達這個約束，結果幾乎相同，但運算量差了一百倍。

其二，有些點是「有害」的：植被的葉子、飄動的塑膠袋、走動的人，這些點在下一幀就不在原位了，強行配準只會把誤差引入。LeGO-LOAM 的點雲分割步驟正是為了濾除這類不穩定的點。

其三，特徵點是「精選」的：曲率極高或極低的點，恰好是最容易在下一幀被正確辨識出來的點——這與第 9 章視覺 SLAM 偏愛角點的道理完全相同（「白牆上找不回任何一個點」）。

這個案例給同學一個超越技術的啟示：更多資料不等於更好的結果，關鍵在於資料的品質與代表性。這個原則在機器學習、統計、工程判斷上處處適用。

案例 18-2 地面的價值：LeGO-LOAM 的巧思

LeGO-LOAM 的名字裡有「Ground-Optimized（地面最佳化）」，這個看似樸素的設計其實非常聰明。

思考一下：對一台在地面行駛的機器人而言，地面是什麼？它是一個永遠存在、極為穩定、面積巨大的平面特徵。而且它提供的約束非常明確——地面能精準地告訴機器人「你離地多高、機身有沒有前後傾或左右傾」，也就是垂直位移與滾轉、俯仰這三個自由度。

LeGO-LOAM 因此把 6 個自由度拆成兩組分別求解：先用地面點的平面特徵求出垂直位移與滾轉、俯仰角，再用其他邊緣特徵估計水平位移與偏航角，並把前一步的結果當作約束。這樣做的好處是：每一步要解的未知數變少，問題更好收斂、運算更快、也更穩定。

這個案例展示了一種重要的工程思維：善用場域的先驗知識。地面載具「一定在地上」是一個免費的、可靠的假設，不利用它就浪費了。當然代價是通用性——這個假設在無人機上就完全不成立。這再次呼應第 15 章的觀察：技術的設計取向，由應用需求決定。

案例 18-3 實作的魔鬼細節：硬體規格的坑

許多同學在專題中興沖沖地下載 LIO-SAM 或 LeGO-LOAM，卻卡在「跑不起來」。原

因往往不是演算法，而是硬體規格不符。以下是幾個真實的坑：

- IMU 軸數不足：與原始 LOAM 實作相同，LIO-SAM 只能搭配九軸 IMU（能提供滾轉、俯仰與偏航估計）。買了六軸 IMU 的同學會直接卡關。
- 光達類型不支援：目前僅支援機械式光達。固態光達（第 8 章）的資料格式不同，需要額外適配。
- 缺少必要欄位：系統需要每點的時間戳記與線號（ring）。官方文件明確說明：當光達以 10 Hz 旋轉時，每點的時間戳記應在 0 到 0.1 秒之間；線號則指出該點屬於感測器的哪一個通道，用來正確地組織點雲。若驅動程式沒輸出這些欄位，就必須自行改寫。
- 特定光達最佳化：LeGO-LOAM 特別針對水平放置於地面載具上的 16 線光達最佳化，並假設掃描中總是存在地平面。用在其他配置上效果會打折。

這個案例的教學意義在於：開源系統不是「下載就能用」。閱讀官方文件的硬體需求章節，是專題開始前必做的功課。這個習慣能省下數週的挫折——這也是本書每章都詳述「前置條件」與「常見失敗」的原因。

實作活動

實作 18-1 光達里程計與特徵提取

目的：親手實作曲率特徵提取、觀察邊緣與平面特徵的分布，並執行完整的光達里程計系統，理解漂移與閉環的作用。本實作以公開資料集為主，不需 3D 光達硬體。

第一部分：特徵提取實作（全體）

1. 下載一段公開的 3D 光達資料（如 KITTI 或 LeGO-LOAM 官方提供的校園資料集），取出單一幀點雲。
2. 用 Python 實作公式一的粗糙度計算：對每個點，取同一線號上左右各數個鄰居，計算 c 值。

3. 依 c 值分類：取最高的 2% 為邊緣特徵、最低的 20% 為平面特徵，用不同顏色顯示（可用 Open3D），觀察它們分別落在環境的什麼位置。
4. 驗證直覺：邊緣特徵是否集中在柱子、樹幹、牆角？平面特徵是否集中在地面與牆面？若不是，調整鄰居數量與門檻再試。
5. 統計特徵點數佔原始點數的比例，體會 LOAM 的減量效果。

第二部分：執行光達里程計（全體或大學部）

1. 在 ROS 環境中安裝 LeGO-LOAM 或 A-LOAM（注意檢查案例 18-3 的硬體與資料格式需求）。
2. 播放資料集，在 RViz 中即時觀察：特徵點雲、估計軌跡、逐步累積的 3D 地圖。
3. 觀察漂移：讓資料播放完一個大迴路，比較起點與終點的位置差距，量化累積漂移。
4. 開啟閉環偵測後重跑一次，觀察閉環觸發時整條軌跡與地圖如何被拉正（第 12、15 章的震撼時刻）。

第三部分：系統比較與退化實驗（大學部）

1. 在同一段資料上分別執行 LeGO-LOAM、LIO-SAM（若有 IMU 資料）與 Fast-LIO，比較三者的軌跡精度、運算負擔與地圖品質。
2. 用第 17 章案例 17-1 的「牆厚度」方法，量化比較三張地圖的品質。
3. 退化場景實驗：找一段以長走廊為主的資料（或自行採集），比較純光達與光達加 IMU 的表現差異，驗證 18.5 節的論述。
4. 若有 IMU 資料，刻意關閉 IMU 融合再跑一次，量化 IMU 帶來的改善幅度。

討論問題

1. 你的特徵點佔原始點數的百分之幾？若把這個比例提高一倍，配準精度會提升嗎？運算時間增加多少？

2. 觀察你提取的特徵：在植被茂密或雜亂的區域，特徵分布合理嗎？這印證了 LeGO-LOAM 為何要先做點雲分割？
3. 大迴路的累積漂移是多少公尺？佔總行走距離的百分之幾？閉環修正後改善了多少？
4. (大學部) 在長走廊場景，哪一個方向的誤差最大？這與第 13.6 節的 2D 走廊困境、第 17.3 節的結構退化是否為同一問題？
5. (大學部) 依表 18-1，若要為一台大學的巡檢機器狗選系統，你會選哪一個？考量因素有哪些？

延伸挑戰 (大學部)

其一：實作一個最簡化的光達里程計——只用平面特徵，以點到面 ICP (第 17 章) 連續配準相鄰兩幀並累加位姿，把軌跡與資料集真值比較，繪製誤差隨距離成長的曲線。接著加入邊緣特徵，觀察精度改善多少，親身驗證 18.2 節「兩種特徵互補」的論述。其二：採集一段大學走廊的實測資料 (依第 19.8 節階段一的做法)，在其上執行本章的系統並評估品質，作為第 31 章專題四的前導研究。

延伸閱讀

1. J. Zhang and S. Singh, "LOAM: Lidar Odometry and Mapping in Real-time," Robotics: Science and Systems, 2014. (LOAM 原始論文，本章主要依據，CMU 機器人研究所出版)
2. T. Shan and B. Englot, "LeGO-LOAM: Lightweight and Ground-Optimized Lidar Odometry and Mapping on Variable Terrain," IROS, 2018. (地面最佳化與兩步最佳化的原始論文)
3. T. Shan et al., "LIO-SAM: Tightly-coupled Lidar Inertial Odometry via Smoothing and Mapping," IROS, 2020. (因子圖緊耦合的代表作)

4. W. Xu and F. Zhang, "FAST-LIO: A Fast, Robust LiDAR-inertial Odometry Package by Tightly-Coupled Iterated Kalman Filter," IEEE RA-L, 2021. (以及 FAST-LIO2, IEEE T-RO, 2022)
5. LeGO-LOAM 與 LIO-SAM 開源專案 (GitHub) . (含官方資料集、硬體需求說明與參數設定，實作必讀)
6. A-LOAM 開源專案 (GitHub, HKUST Aerial Robotics) . (LOAM 的簡潔重實作，程式碼易讀，適合教學研讀)
7. KITTI Vision Benchmark Suite 官方網站. (自駕車 3D 光達的標準評測資料集，含真值軌跡)

小結

1. LOAM 由 Zhang 與 Singh 於 2014 年提出，核心洞見是「不需要用上所有的點」；它把 SLAM 拆成里程計與建圖兩個平行任務，藉由提取邊緣與平面特徵，在結構化環境中以低運算成本達成高精度，成為後續光達 SLAM 研究的共同基礎。
2. 特徵以局部粗糙度（曲率）分類：高曲率為邊緣特徵（柱子、牆角）、低曲率為平面特徵（牆面、地面）；兩者提供互補的幾何約束——平面約束垂直於面的移動、邊緣約束垂直於線的移動，缺一則自由度無法完全鎖定。
3. 雙層架構是 LOAM 的第二項創新：高頻里程計（約 10 Hz）提供即時位姿與良好初值，低頻建圖（約 1 Hz）與全域地圖精細配準以消除漂移，兩者整合後輸出高頻且精確的位姿。此外必須做運動變形補償。
4. LeGO-LOAM 以點雲分割濾除雜訊、善用地平面做兩步 Levenberg-Marquardt 最佳化，在低功耗嵌入式系統上即時運行，以更底運算成本達到相當或更好的精度，但假設掃描中總是存在地平面。

5. LIO-SAM 以因子圖搭配貝氏樹實現 IMU 緊耦合與漂移感知的閉環整合；Fast-LIO 系列則走免特徵提取、以迭代擴展卡爾曼濾波緊耦合的路線，適合運算受限平台與快速運動。
6. 純光達在快速運動與幾何退化環境（長廊、開闊地）會失效，IMU 恰好補上這三個缺口（提供初值、退化方向的獨立約束、運動變形補償），而光達回報以不漂移的觀測校正 IMU 零偏；緊耦合優於鬆耦合。
7. 自主巡檢需要 3D 而非 2D，因為要處理地形起伏、立體障礙、三維巡檢目標與資產建模；平台可選輪型、履帶或四足，而四足的步態震動使 IMU 緊耦合成為必要。

本章完成了 3D 光達 SLAM 的核心技術。從第 17 章的點雲處理到本章的 LOAM 系列，同學已經具備在三維世界中定位建圖的完整知識。下一章我們把這些技術帶進真實場域——第 19 章的自主巡檢機器人，處理巡檢點排序、重複定位精度與長期地圖維護這三件決定系統成敗的事，並以此為第五篇作結。

台灣自編大學教科書

@prof

《地圖建構與同步定位》

Simultaneous Localization and Mapping, SLAM

第五篇 3D 光達 SLAM 與自主巡檢

第 19 章

自主巡檢機器人與場域實務

編者：李世淵（機器人叫獸）

助教：李天宇、李宇晴

大學智慧機器人學程 / 高中 AI 機器人社團課程

本章在全書的位置

第 17 與 18 章把三維光達 SLAM 的技術備齊了：點雲怎麼處理、特徵怎麼挑、位姿怎麼估、掃描期間的運動怎麼補償。本章要問的是另一個問題——當這些技術必須每天在同一棟建築裡自己跑上三小時、連續跑一年，會發生什麼事。


答案是：技術指標不再是唯一的重點。一台巡檢機器人的成敗，往往不取決於它的 SLAM 有多準，而取決於三件更瑣碎的事——巡檢點的順序排得好不好、每天能不能停在同一個位置、以及三個月前建的地圖今天還能不能用。這三件事正是本章 19.4、19.5、19.6 三節的主題，也是本章三張實驗圖要回答的問題。

本章在全書的角色，與第 16 章的掃地機器人對稱：第 16 章是 2D SLAM 的落地應用，本章則是 3D SLAM 的落地應用。兩章都在示範同一件事——把演算法放進每天要用的產品裡，真正的難題才開始。

圖 19-0 第 19 章的連結地圖

第五篇的技術基礎

第 17 章 點雲處理 第 18 章 LOAM 與特徵配準



【第 19 章 自主巡檢：讓技術每天跑一年】

路線規劃 — 重複定位 — 地圖維護 — 資料到數位分身



第六篇 視覺 SLAM 第七篇 無人機與邊緣 AI

第八篇 ROS 實作 第九篇 語意導航

學習目標

巡檢是 3D SLAM 最成熟的商業應用，也是最能把本書前十八章串起來的場域。本章從需求出發，依序處理巡檢機器人的技術堆疊、平台選型、路線規劃、重複定位與長期維護，最後以台灣的研究與產業現況，以及一個可執行的校園專題作結。讀完本章，同學應能：

1. 說明巡檢自主化要解決的問題，以及它與一般導航任務的根本差異。
2. 說明巡檢機器人的技術堆疊，並指出每一層對應本書的哪些章節。
3. 比較輪型、履帶、四足與無人機四種平台的適用場域與代價。
4. 說明巡檢點路線規劃的問題本質，並能估算排序對續航的影響。
5. 解釋重複定位精度為何是巡檢的關鍵指標，以及它與場域幾何的關係。
6. 說明長期運行下地圖維護的必要性，並能設計地圖更新策略。
7. 舉例說明台灣在巡檢機器人上的研究與產業成果，並據以規劃一個校園巡檢專題。

核心概念

名詞	意義	關聯章節
巡檢點 (Waypoint)	機器人必須抵達並以特定姿態採集資料的位置	19.4、19.5
重複定位精度	多次回到同一巡檢點時，位姿的離散程度	19.5、第 11 章
覆蓋與巡檢的差異	覆蓋要走遍每一格；巡檢只需走訪指定的點	19.4、第 16 章
路線最佳化	在巡檢點之間找出最短的巡迴順序 (旅行推銷員問題)	19.4
地圖維護	依環境變動更新先驗地圖，維持長期可定位	19.6、第 13 章
多期 SLAM	跨日期的多趟軌跡合併為同一張地圖	19.6、第 15 章
數位分身	以巡檢資料建立的三維模型與資產紀錄	19.7、第 17 章
退化場域	幾何約束不足、定位易失敗的區域 (長走廊、空曠大廳)	19.5、第 17、18 章

19.1 為什麼巡檢要自主化

巡檢是一項古老而乏味的工作：有人拿著紀錄表，每天沿著固定路線走一圈，看儀表讀數、聽設備聲音、摸管線溫度、確認門窗與消防設備。這件事看似簡單，卻有三個難以靠人力克服的問題。

人工巡檢的三個結構性問題

- 一致性：人會疲勞、會分心、會「昨天看過今天就跳過」。同一個巡檢點由不同人、在不同時間檢查，標準很難一致。
- 頻率：人力有限，巡檢頻率往往被壓到最低。一週兩次的巡檢，代表設備最長可能有三天處在無人察覺的異常狀態。
- 環境風險：變電所、高壓設備、地下涵洞、災後建築、輻射區——有些地方本來就不該讓人常去。

自主巡檢機器人正面回應了這三點。它的紀錄完全一致、可以每天甚至每小時跑一趟、而且可以進入人不該進的地方。更重要的是，它把巡檢從「發現故障」升級為「預測故障」——因為只有在資料夠密、夠一致時，趨勢才看得出來。

巡檢與一般導航的四個差異

同學容易把巡檢當成「導航 + 拍照」，但兩者的工程重點其實相當不同：

面向	一般導航	巡檢任務
路線	每次可能不同，求抵達	每天相同，求重複
定位要求	公尺級即可安全行走	公分級，否則拍不到同一個角度
地圖	跑一趟建一次	建一次用一年，必須維護
成功標準	有沒有到	資料有沒有可比性

其中「重複」兩個字是關鍵。巡檢資料的價值來自於跨時間比較——今天的紅外熱像要和上週的比，才知道溫度是不是在上升。若兩次拍攝的位置與角度差了半公尺，影像就無法直接比對，所有的趨勢分析都失去基礎。這就是 19.5 節要處理的問題。

19.2 巡檢機器人的技術堆疊

一台巡檢機器人是本書前十八章的總和。本節由下而上拆解它的五層結構，並指出每一層對應哪些章節。

層級	內容	本書章節
感測層	3D 光達、IMU、輪速編碼器、RGB 與紅外熱像、麥克風	第 7、8、9 章
定位建圖層	3D SLAM 建圖、先驗地圖定位、閉環修正	第 17、18 章
導航層	全域路徑規劃、區域避障、巡檢點抵達控制	第 3 章、第八篇

任務層	巡檢點管理、路線排程、電量與回充決策	19.4、19.6
資料層	資料標註位置與時間、異常偵測、數位分身與報表	19.7、第九篇

巡檢任務層：本章新增的一層

前三層在第 17、18 章與第八篇都有完整處理，本章真正新增的是任務層與資料層。任務層要回答的問題聽起來很行政，實際上全是最佳化問題：十二個巡檢點該用什麼順序走？電量只剩四成時要先回充還是先跑完？某個點今天定位失敗了，要重試幾次才放棄？

這些決策的品質，直接決定了機器人每天能完成多少工作。19.4 節會用一個實驗說明：光是把巡檢點的順序排對，就能省下四成五的行走距離——而行走距離就是電池，電池就是一天能跑幾趟。

19.3 平台選型：輪型、履帶、四足、無人機

巡檢機器人沒有通用平台，選型幾乎完全由場域決定。本節比較四種主流選擇。

平台	優勢	限制	典型場域
輪型	續航最佳、成本最低、SLAM 最穩定	無法上樓梯、越障能力差	廠房、走廊、機房、變電所
履帶	越障與斜坡能力佳、穩定度高	體積重量大、轉彎磨耗地面	戶外、災後現場、工地
四足	地形適應力最強、可上樓梯	續航短、成本高、步態震動不利 SLAM	多樓層、涵洞、不平地面
無人機	可達高處與橋下、速度快	續航以分鐘計、室內定位困難	橋梁、塔架、大型結構外部

四足平台的 SLAM 難題

四足機器人近年成為巡檢的熱門選擇，但它對 SLAM 是嚴峻考驗。原因是步態震動：每一步

落地都讓機身產生高頻的俯仰與滾轉，而第 18.3 節談過的運動變形補償，在這種非等速的劇烈運動下特別容易失準。這也是為什麼四足平台幾乎一定要搭配高品質 IMU 與緊耦合的光達慣性里程計（第 18.5 節）。

選型的三個提問

場域有沒有高低差？有樓梯或門檻就排除輪型。

一趟巡檢要多久？超過一小時，四足與無人機的續航就會成為瓶頸。

巡檢對象在哪個高度？在天花板或橋下，地面平台再強也看不到。


最後一問最實際：這個場域的 SLAM 會不會退化？長走廊與空曠大廳（第 17.3 節、圖 18-2）對任何平台都是難題，必須先確認再採購。

19.4 巡檢點規劃與路線最佳化

巡檢與第 16 章的掃地任務有一個根本差異：掃地要「走遍每一格」（覆蓋路徑規劃），巡檢只需「走訪指定的點」。這個差異把問題從覆蓋問題換成了旅行推銷員問題——給定一組必須造訪的點，求最短的巡迴順序。

這個問題在理論上是困難的（隨點數成階乘成長），但在巡檢的實務規模下非常好處理。一層樓通常只有十幾個巡檢點，用最近鄰貪婪法得到初始解、再以 2-opt 反覆改良，幾毫秒內就能得到接近最佳的路線。

圖 19-1 巡檢點排序：一條路線決定了四成五的電池



本書以一層 34×14 公尺的系館樓層做實驗：一條貫穿的走廊、上下兩排教室與實驗室、一座電梯井與一間樓梯間，沿途設定十二個巡檢點——電梯門、門禁讀卡機、配電箱、消防栓、空調主機與實驗室門口。機器人從走廊左端的充電座出發，走訪全部十二點後回到充電座。

圖(a) 是使用者在 App 上隨手點選巡檢點、未經排序的結果：路徑在走廊上來回穿梭，總長 219 公尺。圖(b) 是同樣十二個點、經 2-opt 最佳化後的路線：機器人沿走廊單向前進，順路進出兩側房間，總長 121.5 公尺。兩者造訪的點完全相同，差別只在順序。

圖(c) 把四種排序並列。隨機順序 (200 次平均) 219.3 公尺，依編號順序 138.5 公尺，最近鄰貪婪 125.2 公尺，2-opt 最佳化 121.5 公尺。從隨機到最佳化省下 45%，而從貪婪再到 2-opt 只多省 3%——這說明一件很實用的事：排序的大部分效益來自「別亂走」，而不是來自精巧的演算法。一個十行的最近鄰法就能拿走九成以上的好處。

圖(d) 顯示差距是如何累積的。三條曲線在前兩三個點幾乎重疊，但隨機順序每多走一個點就多付一次代價，到第十二點時已經落後近百公尺。換算成實務影響：以 0.5 公尺 / 秒的巡檢速度計，這條多出來的路要多花三分多鐘，而若機器人一天要跑八趟，就是每天多耗 26 分鐘的電池與馬達壽命。

實作上的三個修正

本實驗的距離是走廊與房間的實際可通行最短路徑（以 BFS 在佔據格上計算），不是直線距離。用直線距離排序會在有隔牆的樓層嚴重失真。

真實巡檢還有順序限制：某些點必須在特定時間拍攝（例如上班前的門禁），這屬於帶時間窗的旅行推銷員問題，需在最佳化時加入限制。


跨樓層時電梯是瓶頸節點，等待時間往往比行走時間長，應把「同一層的點一次走完」設為硬性限制。

電量不足以跑完全程時，問題變成「在有限里程下最大化巡檢價值」，此時需要為每個巡檢點設定優先權。

19.5 重複定位精度：能不能每天停在同一個位置

這是巡檢最關鍵、也最容易被低估的指標。機器人要拍攝同一個儀表、比對同一面牆的熱像，就必須每天停在同一個位置、用同一個角度。業界常見的要求是數公分——這遠高於一般導航「不要撞到東西」的公尺級需求。

圖 19-2 同一個巡檢點、重複 25 次：停得準不準



實驗設定如下：機器人從充電座出發抵達某個巡檢點，途中里程計累積了約 1 公尺的誤差（相當於 60 公尺路程、1.5% 的漂移率）。此時有兩種選擇——直接相信里程計，或以光達掃描比對先驗地圖重新定位。十二個巡檢點各重複 25 次，共 300 次試驗。

圖(b) 的兩個分布說明了一切。僅靠里程計時，誤差集中在 1 公尺附近，沒有任何一次達到 0.10 公尺的目標；改用先驗地圖定位後，絕大多數試驗落在 1 公分以下，中位數 0.004 公尺，92% 的試驗達標。圖(c) 把這個對比濃縮成一個數字：0% 對 92%。

但圖(a) 才是本節真正的重點。它逐點顯示定位精度，而同學會立刻注意到：藍色的房間內巡檢點，誤差中位數在 1 到 6 公釐之間，失敗率 0 到 8%；而紅色的走廊巡檢點——電梯門與樓梯間——明顯較差，其中樓梯間的失敗率高達 48%，接近一半的嘗試會定位失敗。

原因同學應該已經很熟悉了：長走廊沿軸向缺乏幾何約束（第 17.3 節的結構退化、圖 18-2 的資訊矩陣分析）。機器人知道自己貼著哪一面牆，卻說不清沿走廊走了多遠。這個在第 17、18 章還只是理論限制的現象，到了巡檢場域就變成具體的產品缺陷：那個巡檢點每兩次就有一次拍歪。

這帶出一個重要的設計原則：巡檢點的位置不該只由「要檢查什麼」決定，也要考慮「那裡定位得準不準」。把巡檢點從走廊中央往門口挪兩公尺，讓機器人能同時看到門框與兩側牆面，往往比升級感測器更有效，而且不用花錢。

提高重複定位精度的四個手段

移動巡檢點：優先選擇幾何特徵豐富的位置（轉角、門框、設備密集處）。

加裝人工地標：在退化區域貼上 AprilTag 或反光標籤（第 4 章），用極低的成本提供絕對位置參考。

多感測器互補：在走廊這類光達退化的地方，相機的視覺特徵（第六篇）或 UWB 標籤（第 4 章）可以補上缺少的那個方向。


接受並處理失敗：定位信心不足時，讓機器人後退一公尺重新嘗試，或標記該筆資料為「位置不可靠」，而不是拍一張沒人知道拍歪了的照片。

19.6 長期運行：地圖維護與環境變動

前兩節處理的是「今天這一趟」，本節要問的是「一年後還能不能跑」。這是巡檢與一次性建圖任務最大的差別：地圖不是成果，而是需要維護的資產。

真實場域會變。桌椅被搬動、走廊堆了紙箱、實驗室換了設備、門今天開著明天關著。這些變動單獨看都很小，累積起來卻足以讓定位失效——因為掃描匹配比對的正是這些東西。

圖 19-3 地圖會過期：環境變動對定位成功率的影響



圖(a) 是建圖當天的樓層，圖(b) 是一段時間後的同一層——紅色標出與原地圖不符之處：房間裡多出的桌椅、走廊上暫置的物品，合計改變了約 12% 的可通行面積。從人的角度看，這層樓「還是那層樓」；但從掃描匹配的角度看，有八分之一的觀測對不上。

圖(c) 是量化的結果，也是本章最該記住的一張圖。紅線是沿用建圖當天舊地圖的定位成功率：環境變動 0% 時 93%，變動 5% 時降到 72%，變動 15% 時只剩 35%——不到一年，系統就廢了一半。藍線則是每趟巡檢後更新地圖：即使環境變動 15%，成功率仍維持在 74%。

兩條線的分岔說明了地圖維護不是錦上添花，而是巡檢系統能否長期運作的分水嶺。值得注意的是，藍線也不是水平的——它從 92% 緩降到 74%，因為環境變動越大，暫時性的物品（紙箱、推車）在地圖裡占比越高，而這些東西明天就不在了。這正是第 15.8 節提過的終身建圖問題：地圖既要「記得」永久結構，又要「忘記」臨時障礙。

三種地圖維護策略

- 定期重建：每隔固定期間（例如每季）重新建一次圖。做法最簡單，但重建期間系

統無法運作，且會丟失歷史對應關係。

- 增量更新：每趟巡檢後把新觀測併入地圖，以佔據機率的上下限控制舊資訊的遺忘速度（第 13.5 節）。本實驗的藍線即屬此類。
- 分層地圖：把地圖分成「永久層」（牆、柱、門框）與「暫態層」（桌椅、堆置物）。定位只用永久層，避障則兩層都用。這是目前商用系統最常見的做法，也最能同時滿足記得與遺忘。

19.7 巡檢機器人的功能與產業應用

前面六節處理的是「怎麼走到定點」。但一台巡檢機器人到了定點之後要做什麼、能做到什麼程度，才是使用者真正買單的理由。本節把巡檢機器人的功能攤開來看，再依場域說明不同產業的需求差異，最後介紹這條產業鏈由哪些角色組成。

一、巡檢機器人的核心功能

巡檢機器人的功能可分為「移動」「採集」「判讀」「管理」四類。以下清單整理了目前商用機型普遍具備或正在導入的能力，並標出每一項背後所需的技術與本書對應章節。

類別	功能	所需技術	本書章節
移動	自主導航與避障	3D SLAM、路徑規劃、代價地圖	第 17、18 章、第八篇
移動	定點停靠（公分級重複定位）	先驗地圖定位、精定位控制	19.5、第 11 章
移動	自動回充與續航管理	電量模型、排程決策	19.4、19.6
移動	跨樓層移動（電梯整合）	拓撲地圖、設備通訊介面	19.4、19.8
採集	可見光影像定點拍攝	雲台控制、曝光補償	第 9 章
採集	紅外熱像量測	熱像儀、溫度標定	第 9 章、19.7

採集	異音擷取與頻譜記錄	麥克風陣列、聲學分析	19.7
採集	氣體、溫濕度與輻射偵測	環境感測器整合	19.7
判讀	儀表指針與數字讀取	影像辨識、OCR	第九篇
判讀	設備外觀缺陷偵測	物件偵測、異常偵測	第九篇
判讀	熱點與溫升趨勢分析	跨時間資料比對	19.5、19.6
管理	資料標註三維座標與時間	位姿紀錄、時間同步	第 10 章、19.6
管理	異常分級與工單派送	規則引擎、後台整合	19.7
管理	數位分身與資產紀錄	三維重建、點雲顏色化	第 17.5、17.6 節

同學可以從這張表看出一個清楚的分界：「移動」與「採集」兩類功能，目前的商用機型已經相當成熟，而且技術基礎全部落在本書第一至八篇；「判讀」一類則是現階段的前沿，多數機型仍只負責把資料傳回後台由人判讀，自動判讀的能力正在逐步導入——這正是第九篇要處理的主題。

二、不同場域的功能需求差異

巡檢機器人沒有通用規格。同樣是「巡檢」，電力場域與地下管道所需的功能幾乎沒有重疊。

下表整理四種常見場域的差異，可作為專題選題或需求書撰寫的起點。

場域	主要巡檢對象	關鍵功能	環境難題
電力設施	變壓器、開關、電容器、接頭	紅外熱像、異音偵測、儀表判讀	戶外全天候、電磁干擾、高壓安全距離
橋梁與結構	裂縫、鏽蝕、鋼纜索力	高解析影像、三維定位、表面正射影像	無衛星訊號、高空作業、需達次毫米解析度
廠房與倉	管線、機台、消防設	定點影像、溫度、氣體偵	人車混流、環境每日變動、

儲	備、料架	測	產線不可停
地下管道 與涵洞	結構變形、積水、氣體	防水防塵、氣體偵測、照明	無光源、狹窄、通訊中斷、 無法救援

其中橋梁檢測的需求最能說明「功能決定平台」。要辨識 0.2 至 0.3 公釐的裂縫，代表載具必須能貼近結構表面、相機必須有足夠解析度；而橋下與結構內部收不到衛星訊號，載具又必須完全依靠自身的 SLAM 維持位置。這兩個要求互相拉扯——飛得越近定位越困難——正是結構檢測無人機最核心的工程難題，也是第五篇與第七篇的交會點。

三、量化效益：功能如何轉換成價值

巡檢機器人的採購決策通常不看技術指標，而看三個可量化的效益。以下數字來自國內已實際部署的案例，可作為估算的參考。

- 巡檢頻率：國內某電力事業單位導入戶外巡檢機器人後，同一座變電所的巡檢頻率由人員每週兩次提升為機器人每日一次。這代表異常被發現的最長延遲從三天縮短為一天，也讓預測性維護第一次有足夠密集的資料基礎。
- 運算資源：國內某法人研究機構報告，其為巡檢機器人開發的導航演算法僅占用機器人運算資源的 25%，而傳統演算法需要 65% 至 70%。對一台要同時跑導航與影像辨識的機器人而言，省下的運算資源直接決定了它能不能即時反應。
- 檢測涵蓋率：以橋梁為例，國內車行橋梁超過 2.3 萬座，主管機關的目標是 100% 檢測。這個數量級使人工檢測在本質上不可行，也說明自動化在某些場域不是效率問題，而是可行性問題。

四、產業鏈由哪些角色組成

巡檢機器人是少數在台灣具備完整供應鏈的機器人應用。以下依行業別說明各環節的角色，讓同學了解這個產業的樣貌與可能的就業方向。

環節	行業別	在巡檢機器人中的角色
----	-----	------------

感測元件	光達製造業	提供 2D / 3D 光達，決定建圖品質與成本
感測元件	光學與熱像模組業	可見光相機、紅外熱像儀、雲台
驅動元件	電機與馬達製造業	輪組、關節馬達，決定續航與越障能力
控制元件	工業控制器與機器人控制器業	運動控制、即時系統
運算平台	邊緣運算與嵌入式系統業	車載電腦，決定能跑多複雜的演算法
整機整合	電子代工與系統整合業	機構設計、整機組裝、量產與驗證
軟體與演算法	機器人軟體與 AI 服務業	SLAM、導航、影像辨識、後台平台
研究法人	工業技術研究法人	平台技術開發、產業串聯、場域驗證
終端用戶	公用事業、製造業、交通主管機關	提出需求、提供驗證場域、採購導入

值得注意的是「研究法人」這個環節。在台灣，法人研究機構往往扮演平台開發與產業串聯的角色：由法人設計本體與 AI 核心，再由各行業的廠商供應零組件與整機整合，最後由公用事業或製造業提供場域驗證。這種分工讓資源有限的單一廠商也能參與高複雜度的機器人開發，也是同學日後若投入這個領域最可能接觸到的合作模式。

從功能到規格：寫一份巡檢需求書

先定義巡檢對象與判讀標準：要看什麼、看到什麼程度算異常。這一步決定了相機解析度、熱像精度與停靠精度的要求。

再定義場域條件：有無高低差、是否戶外、有無衛星訊號、環境多久變動一次。這一步決定平台型式與地圖維護策略。

然後定義頻率與續航：一天幾趟、一趟多久、充電要多久。這一步決定電池容量與路

線最佳化的重要性。

最後才談技術規格。先寫需求再挑規格，是避免「買了最貴的感測器卻解決不了問題」最有效的方法——這也是第 8 章感測器選型討論的延伸。

19.8 場域專題：南部科技大學的走廊、電梯與實驗室

本節把前面七節落實成一個可執行的專題規劃。場域設定為台灣南部一所科技大學的系館——這類校園是極佳的巡檢教學場域：有長走廊（退化場景）、有電梯與樓梯（跨樓層）、有實驗室（貴重設備與門禁）、也有真實的管理需求。

場域分析：三種環境的不同挑戰

場域	主要挑戰	技術對策	對應章節
長走廊	沿軸向幾何退化、定位失敗率高	IMU 緊耦合、人工地標、巡檢點改設於門口	第 17.3、18.5、19.5
電梯與樓梯間	跨樓層、地圖不連續、金屬反射	分層地圖、電梯作為拓撲節點、四足或輪型分工	19.4、19.6
實驗室	環境每日變動、人員走動、設備更換	分層地圖、動態物體剔除、每趟增量更新	19.6、第 13.5
大廳與中庭	空曠、遠處回波稀疏、玻璃帷幕	降低對光達的依賴、視覺輔助、縮短巡檢點間距	第 8 章、第六篇

五階段專題規劃

1. 階段 1——資料採集：以手推車或機器人載具搭載 3D 光達與 IMU，分別在走廊、樓梯間與實驗室錄製資料集。這一步不需要自主導航，人推著走即可，適合作為大學部的入門作業。
2. 階段 2——離線建圖與比較：以錄好的資料分別執行 LeGO-LOAM、LIO-SAM 與

Fast-LIO (第 18.4 節)，比較三者在各場域的軌跡精度、地圖品質與運算負擔，並以第 17 章案例的「牆厚度」方法量化地圖品質。

3. 階段 3——退化場景實驗：專門針對長走廊，比較純光達與光達加 IMU 緊耦合的差異，量化 IMU 帶來的改善。這是最有研究價值的一環，也直接對應本章圖 19-2(a) 那兩根紅色長柱。
4. 階段 4——巡檢點設定與路線最佳化：在建好的地圖上設定十至十五個巡檢點，實作本章 19.4 節的最近鄰加 2-opt 規劃，並實際量測排序前後的行走距離與耗時，重現圖 19-1。
5. 階段 5——長期運行與地圖維護：連續數週每日執行巡檢，記錄每個巡檢點的定位成功率，觀察它如何隨環境變動而下降，再導入增量更新或分層地圖，量化改善幅度。這一階段可延伸為研究所題目。

教學與研究價值

這個專題的優點是層次分明：階段一、二適合大學部課程作業，階段三、四適合專題生，階段五可延伸為碩士論文。而且成果具體可展示——一份校園的三維模型、一套每日運行的巡檢紀錄，對外說明時遠比任何投影片有說服力。

更重要的是，它把本書前十八章的內容全部用上了：第 8 章選光達、第 7 章配 IMU、第 10 章校外參、第 17 章處理點雲、第 18 章跑 LOAM、第 12 章做閉環最佳化，再加上本章的路線規劃、重複定位與地圖維護。一個做完這五階段的學生，已經具備進入業界巡檢機器人團隊的完整能力。

公式或流程

一、巡檢任務的三個評估指標

巡檢系統的品質可用三個指標衡量，三者互相拉扯：

巡檢完成率 = 成功採集資料的巡檢點數 / 總巡檢點數

重複定位精度 = 多次造訪同一巡檢點時，位姿的標準差

單趟耗時 = 總行走距離 / 平均速度 + Σ 各點的採集時間

提高完成率往往要增加重試次數，因而拉長單趟耗時；而縮短耗時又可能犧牲定位精度。工程上的取捨正是產品設計的核心，與第 16.4 節掃地機器人的三個指標完全同構。

二、巡檢路線的最佳化問題

設巡檢點集合為 $P = \{p_1, \dots, p_n\}$ ，充電座為 p_0 ， $d(i, j)$ 為兩點之間的可通行最短路徑長度（非直線距離），求一個排列 π 使總行走距離最小：

$$\min d(p_0, p_{\pi(1)}) + \sum_{k=1}^{n-1} d(p_{\pi(k)}, p_{\pi(k+1)}) + d(p_{\pi(n)}, p_0)$$

這是旅行推銷員問題。實務解法為兩步：先以最近鄰貪婪法求初始解，再以 2-opt 反覆交換任兩段路徑的順序，直到無法再改善。本章圖 19-1 的實驗顯示，貪婪法已能取得九成以上的效益。

三、地圖維護的佔據機率更新

增量更新的核心是讓舊資訊能被新觀測覆蓋。沿用第 13.2 節的對數勝算比，但為其設定上下限：

$$l_t = \text{clamp}(l_{t-1} + l_{\text{meas}}, -l_{\text{max}}, +l_{\text{max}})$$

上下限 l_{max} 決定了地圖的「可塑性」： l_{max} 越大，地圖越相信歷史、越不容易被新觀測改變； l_{max} 越小，地圖越容易遺忘。長期巡檢系統通常取較小的 l_{max} ，以換取對環境變動的適應力。

四、巡檢機器人的一日流程

階段	動作
① 啟動	自充電座出發，以先驗地圖執行全域重定位（第 11 章）
② 規劃	依巡檢點清單與電量，計算當趟路線（19.4 節）

③ 巡檢	前往各巡檢點 → 精定位至公分級 → 採集影像、熱像與聲音
④ 監看	即時記錄定位信心；信心不足時重試或標記資料不可靠
⑤ 回充	電量門檻觸發後返回充電座，並續跑未完成的點
⑥ 更新	把當趟掃描併入地圖（增量更新或分層地圖，19.6 節）
⑦ 報表	資料標上三維座標與時間，輸出異常清單與趨勢圖（第九篇）

案例

案例 19-1 從每週兩次到每天一次：巡檢頻率改變了什麼

國內某電力事業單位自 2017 年起投入智慧巡檢機器人研究，與法人研究機構及國內機器人業者合作，歷時約三年完成一台設計與製造全由國內廠商負責的戶外巡檢機器人，部署於一座二次變電所。

它的感測配置幾乎是本書第二篇的完整實作：3D 光達建立周遭三維地形、3D 相機偵測障礙避免碰撞、雲台上的雙影像模組（含紅外熱像）擔任「眼睛」、麥克風陣列擷取設備聲音、天線支援遠端遙控。它沿固定路線行走、在設定點位拍攝，任務結束後返回專屬小屋無線充電——正是 19.4 與 19.5 兩節所描述的巡檢點與重複定位需求。

但這個案例真正的價值不在硬體，而在制度上的改變：同一座變電所的巡檢頻率，從人員每週兩次提升為機器人每日一次。這個看似平凡的數字意味著異常被發現的最長延遲從三天縮短為一天，也讓「預測性維護」第一次有了足夠密集的資料基礎——例如變壓器接頭開始劣化時，可以在故障發生前排定停電更換。

這個案例也誠實呈現了當時的限制：機器人只負責傳回影像，尚無法自行辨識設備或判讀聲音，後續規劃才是導入 AI 判讀儀表指針與偵測變壓器異音。這個「先解決位置、再解決理解」的順序，正好就是本書的結構——第一至八篇處理「在哪裡」，第九篇才處理「那是什麼」。

案例 19-2 當巡檢對象有兩萬三千座

國內車行橋梁超過 2.3 萬座，而主管機關的目標是全部檢測。這個數字本身就說明了自動化的必要性——若每座橋的人工檢測需要數天，全國檢測一輪就是以年計的工程。這不是效率問題，而是可行性問題。

國內研究團隊發展的做法是把問題拆成兩半：先以無人機把橋「數位化」，建立三維模型並製作表面正射影像；再讓 AI 在影像上找裂縫與劣化，並把發現的缺陷定位回三維模型上。系統還能自動偵測被遮蔽的區域、以額外的影像補償提高覆蓋率——這與第 16 章覆蓋路徑規劃的思路一致，只是從地面搬到了空中。

兩個技術限制值得同學記住。其一是定位：橋下與結構內部收不到衛星訊號，無人機必須完全依靠自身的 SLAM 維持位置，這正是第五篇與第七篇的交集。其二是解析度：要辨識 0.2 至 0.3 公釐的裂縫，代表無人機必須飛得夠近、相機必須夠好，而飛得近又讓定位更困難。這組矛盾是結構檢測無人機的核心工程問題。

另一條路線是放棄通用平台，改用專用機構。針對鋼纜檢測，國內工程顧問機構開發了爬索車：適用鋼纜直徑最大 300 公釐、機體重 13.5 公斤、爬升角度 60 度以上、爬升速度每秒 40 公分以上，在同一根鋼纜上裝設多點感測器，直接量測模態、頻率與索力，取代傳統的震動法。這提醒同學：巡檢不一定要用會走路的機器人，針對單一任務設計的專用機構往往更可靠也更便宜。

案例 19-3 國產四足平台：產業分工與模擬先行

2026 年 7 月，國內主管機關公布了國產四足機器人研發平台的成果，由法人研究機構主導，歷時約一年半建成兩台國產原型機。這個案例的價值不在單一技術，而在它揭示的產業結構。參與分工相當清楚：電子代工業者負責整機整合、視覺系統業者提供影像酬載、電機業者供應關節馬達、光達業者提供感測元件、控制器業者負責運動控制，法人研究機構則包辦本體設計、AI 核心、模擬環境與慣性量測單元。換句話說，從感測到驅動、從控制器到整機，

整條供應鏈都在國內，而平台採開放架構，讓其他團隊能在其上開發應用。

已驗證的應用包括地下涵洞巡檢、自主導航巡檢、群體協作與火場救災——前三項正是本章的主題，而火場救災則呼應第七篇的極端環境討論。法人機構預期第一波需求將出現在工業巡檢、半導體高載重搬運與物流。

最值得同學注意的是訓練方式：團隊以超級電腦搭配通用模擬平台，同時平行模擬四千多隻虛擬機器狗進行 AI 訓練，再部署到實機。這個「先模擬、再部署」的流程將是第 33 章的完整主題，而它已經是國家級專案的標準做法，不再是研究室裡的實驗。

實作活動

實作 19-1 巡檢路線規劃與重複定位評估

目的：以程式實作巡檢任務層的兩個核心問題——路線最佳化與重複定位評估——並在模擬或真實場域中量測它們的影響。本實作以 Python 為主，不需 3D 光達即可完成第一、二部分。

第一部分：路線最佳化（全體）

1. 取一張樓層平面圖（可用第 13 章實作產生的佔據格地圖，或自行以方格紙定義），在上面標出 10 至 15 個巡檢點與一個充電座位置。
2. 以 BFS 或 A* 計算任兩點之間的可通行最短路徑長度，建立距離矩陣。請特別注意：必須用可通行距離，不能用直線距離。
3. 實作最近鄰貪婪法求初始巡迴順序，計算總距離。
4. 實作 2-opt 改良：反覆嘗試反轉路線中的任一段，若總距離變短就接受，直到無法再改善。記錄改善幅度。
5. 與隨機順序（取 100 次平均）比較，重現圖 19-1(c) 的四根長條，並計算排序為你的場域省下多少距離。

第二部分：重複定位評估（全體或大學部）

1. 在模擬環境（或真實機器人）中，讓機器人從同一起點前往同一個巡檢點 20 次，每次加入不同的里程計雜訊。
2. 記錄兩種條件下的最終位姿誤差：僅用里程計，以及用掃描比對先驗地圖重新定位。
3. 畫出兩者的誤差分布（建議用對數橫軸），計算中位數與達標率，重現圖 19-2(b)(c)。
4. 換到不同的巡檢點重做，特別挑一個位於長走廊中央的點與一個位於房間轉角的點，比較兩者的失敗率，驗證 19.5 節關於場域幾何的論述。
5. 依結果調整巡檢點位置：把表現最差的點移動一至兩公尺，重測並記錄改善幅度。

第三部分：長期地圖維護（大學部與專題生）

1. 在模擬環境中隨機加入數個新物件，模擬環境變動，並計算可通行面積的改變比例。
2. 以原始地圖執行定位，記錄成功率；再以更新後的地圖執行，比較兩者，重現圖 19-3(c)。
3. 實作分層地圖：把連續多趟都觀測到的格子標為永久層，只出現一兩趟的標為暫態層。定位僅使用永久層，比較它與全圖定位的成功率。
4. （進階）在真實場域連續一週每日建圖，觀察哪些區域最常變動，畫出一張「變動熱區圖」，作為巡檢點設置與地圖維護策略的依據。

討論問題

1. 在你的場域中，2-opt 相對於隨機順序省下多少距離？若機器人電池能跑 2 公里，排序最佳化讓它每天多跑幾趟？
2. 哪一個巡檢點的重複定位最差？它周圍的幾何有什麼特徵？這與第 17.3 節的結構退化、圖 18-2 的資訊矩陣分析是同一回事嗎？
3. 若把巡檢點從走廊中央移到門口兩公尺處，定位改善了多少？這個「免費」的改善，相對於升級感測器的成本，說明了什麼？

4. 環境變動到什麼比例時，舊地圖的定位成功率開始明顯下降？依這個比例推估，你的場域多久需要更新一次地圖？
5. （大學部）依 19.3 節的平台比較，若要為你的系館選一台巡檢機器人，你會選哪一種？跨樓層的需求會如何改變你的選擇？

延伸挑戰（大學部）

其一：實作帶時間窗的巡檢排程——某些巡檢點必須在指定時段造訪（例如門禁需在上班前、空調需在運轉時），把這個限制加入 2-opt 的接受條件，比較有無限制時的路線長度差異。其二：設計一個「定位信心監看器」，即時計算掃描匹配的資訊矩陣最小特徵值（圖 18-2 的方法），當它低於門檻時主動標記該筆巡檢資料，並把整層樓的信心值畫成熱區圖，找出場域中所有的退化區域。

延伸閱讀

- 國內電力事業戶外巡檢機器人相關報導. (國產戶外巡檢機器人的完整案例，含感測配置與巡檢頻率的改變)
- 國內法人研究機構之巡檢機器人與國產四足機器人研發平台相關發布. (巡檢機器人的產業生態系與分工)
- 國內橋梁檢測無人機與 AI 劣化辨識系統相關報導. (結構檢測的自動化路線與技術限制)
- T. Shan and B. Englot, "LeGO-LOAM," IROS 2018 ; T. Shan et al., "LIO-SAM," IROS 2020. (巡檢機器人最常用的兩套 3D SLAM 系統，第 18 章延伸)
- S. Macenski et al., slam_toolbox 與 Nav2 官方文件. (地圖序列化、純定位模式與導航堆疊，巡檢系統的軟體基礎)
- D. Applegate et al., The Traveling Salesman Problem: A Computational Study, Princeton Univ. Press. (路線最佳化的權威參考，2-opt 與更進階方法)

- 長期定位與地圖維護的相關文獻 (lifelong mapping 、 multi-session SLAM) 。 (本章 19.6 節的理論基礎)

小結

- 人工巡檢有一致性、頻率與環境風險三個結構性問題；自主巡檢機器人以完全一致的紀錄、可提高的頻率與可進入危險場域回應這三點，並把巡檢從「發現故障」升級為「預測故障」。
- 巡檢與一般導航的四個差異是：路線求重複而非抵達、定位要求公分級而非公尺級、地圖要維護而非用完即丟、成功標準是資料的可比性。
- 技術堆疊分為感測、定位建圖、導航、任務與資料五層；前三層由第 17、18 章與第八篇處理，本章新增的是任務層（巡檢點與路線）與資料層（數位分身與報表）。
- 平台選型由場域決定：輪型續航最佳但無法上樓梯、履帶越障佳、四足地形適應最強但續航短且步態震動不利 SLAM、無人機可達高處但續航以分鐘計。
- 巡檢是旅行推銷員問題而非覆蓋問題。實驗顯示：隨機順序 219 公尺、最近鄰貪婪 125 公尺、2-opt 最佳化 121.5 公尺，排序省下 45%，而其中九成效益來自簡單的貪婪法。
- 重複定位精度是巡檢最關鍵的指標。僅靠里程計無法達到 0.10 公尺目標（0%），以先驗地圖定位可達 92%、中位數 0.004 公尺；但走廊上的巡檢點因結構退化，失敗率可高達 48%——巡檢點的位置應同時考慮「要檢查什麼」與「那裡定位得準不準」。
- 地圖是需要維護的資產。沿用舊地圖時，定位成功率隨環境變動從 93% 降到 35%；每趟更新地圖則可維持在 74% 以上。三種維護策略為定期重建、增量更新與分層地圖。
- 巡檢機器人的功能可分為移動、採集、判讀、管理四類；移動與採集已相當成熟，

判讀仍以傳回後台由人判讀為主，自動判讀是現階段的前沿（第九篇）。

- 不同場域的功能需求差異極大：電力設施重熱像與異音、橋梁結構需次毫米解析度與無衛星定位、廠房倉儲面對每日變動、地下管道則需防水防塵與氣體偵測。
- 國內巡檢機器人具備完整供應鏈，由光達、光學、馬達、控制器、邊緣運算、整機整合、軟體演算法、研究法人與終端用戶共同組成；已實際部署的案例顯示，巡檢頻率可由每週兩次提升為每日一次。

承先啟後

第五篇到此完成。從第 17 章的點雲處理、第 18 章的 LOAM 與特徵配準，到本章把這些技術放進每天要跑一年的巡檢系統裡，同學應該能看出一條清楚的線索：演算法決定了系統的上限，而任務層的瑣碎決策決定了它實際能發揮多少。

本章圖 19-2(a) 那兩根特別長的紅柱，也再次指出光達的極限——在幾何退化的長走廊裡，再好的三維光達也說不清自己走了多遠。下一篇我們換一種感測器：從第 20 章起，改用相機「看」。視覺 SLAM 有它自己的難題（白牆、重複紋理、尺度不確定性），但它恰好能在光達束手無策的地方派上用場——牆上的海報、門牌與地板紋理，對相機而言都是清楚的特徵。